

1 Multivariate Verteilungen

Ein p -dimensionaler Zufallsvektor ist ein Spaltenvektor $X = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}$.

Beispiel 1 Sei $\Omega = \{a, b\}$, P das Wahrscheinlichkeitsmaß auf Ω mit $P(\{a\}) = P(\{b\}) = \frac{1}{2}$, $X_1, X_2 : \Omega \rightarrow \mathbb{R}$ seien Zufallsvariablen mit:

$$i = 1, 2 : P(X_i = 0) = P(X_i = 1) = \frac{1}{2}$$

Dann ist $X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$ ein zweidimensionaler Zufallsvektor.

Lässt sich aus den gegebenen Information $P(X_1 + X_2 = 1)$ berechnen?

Nein, denn die eindimensionale Beschreibung (1) enthält nicht genügend Information über die Verteilung von X .

1. Falls $X_1(a) = X_2(a) = 0$ und $X_1(b) = X_2(b) = 1$, dann gilt (1) und $P(X_1 + X_2 = 1) = P(\emptyset) = 0$.
2. Falls $X_1(a) = X_2(b) = 1$ und $X_1(b) = X_2(a) = 0$, dann gilt (1) und $P(X_1 + X_2 = 1) = P(\Omega) = 1$.

Die Verteilung eines Zufallsvektors $X = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}$ lässt sich durch seine Verteilungsfunktion

$F = F_X : \mathbb{R}^p \rightarrow \mathbb{R}$ beschreiben, wobei:

$$\begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p : F(x_1, \dots, x_p) = P(X_1 \leq x_1, \dots, X_p \leq x_p)$$

Beispiel 1.1

$$F(x_1, x_2) = P(X_1 \leq x_1, X_2 \leq x_2) \quad X_1 \equiv X_2 : F(x_1, x_2) = P(X_1 \leq x_1, X_1 \leq x_2) = P(X_1 \leq \min(x_1, x_2))$$

$$= \begin{cases} 0 & \min(x_1, x_2) < 0 \\ P(X_1 = 0) = \frac{1}{2} & 0 \leq \min(x_1, x_2) < 1 \\ 1 & \min(x_1, x_2) \geq 1 \end{cases}$$

Ist $X = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}$ ein diskreter Zufallsvektor, d. h. nimmt X nur endlich oder abzählbar

unendlich viele Werte an, dann lässt sich seine Verteilung durch seine Wahrscheinlichkeitsfunktion $f : \mathbb{R}^p \rightarrow \mathbb{R}$ beschreiben, wobei $f(x) = P(X = x)$, $x \in \mathbb{R}^p$. Es gilt:

$$P(X \in D) = \sum_{j: x^{(j)} \in D} f(x^{(j)}), D \subset \mathbb{R}^p$$

Beispiel 1.2

$$\mathbf{x}^{(1)} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \mathbf{x}^{(2)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$f(\mathbf{x}^{(1)}) = P(X = \mathbf{x}^{(1)}) = P(X_1 = 0, X_2 = 1) = P(\{a\}) = P(\{b\}) = f(\mathbf{x}^{(2)}) = \frac{1}{2}$$

$$f(\mathbf{x}) = 0, \mathbf{x} \in \mathbb{R} \setminus \{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}\}$$

Mit $D = \left\{ \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in \mathbb{R}^2 : x_1 + x_2 = 1 \right\}$ gilt:

$$P(X_1 + X_2 = 1) = P(X \in D) = \sum_{j: \mathbf{x}^{(j)} \in D} f(\mathbf{x}^{(j)}) = \frac{1}{2} + \frac{1}{2} = 1$$

Ein Zufallsvektor $X = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}$ heißt stetig verteilt, wenn es eine Dichte $f: \mathbb{R}^p \rightarrow [0, \infty)$ gibt, sodass:

$$\forall \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p : P(X_1 \leq x_1, \dots, X_p \leq x_p) = \int_{-\infty}^{x_p} \dots \int_{-\infty}^{x_1} f(u_1, \dots, u_p) du_1 \dots du_p$$

1.1 Mehrdimensionale Integrale

Zur Berechnung des zweidimensionalen Integrals $\int_c^d \int_a^b g(x, y) dx dy$ berechne zunächst für jedes festgehaltene $y \in [c, d]$ das innere Integral $G(y) = \int_a^b g(x, y) dx$.

Beispiel 2 Berechne

$$\int_0^2 \int_0^1 xy \, dx \, dy$$

$$g(x, y) = xy$$

$$G(y) = \int_0^1 xy \, dx = \left[\frac{x^2 y}{2} \right]_{x=0}^1 = \frac{y}{2} - \frac{0}{2} = \frac{y}{2}$$

$$\int_0^2 \int_0^1 g(x, y) \, dx \, dy = \int_0^2 G(y) \, dy = \int_0^2 \frac{y}{2} \, dy = \left[\frac{y^2}{4} \right]_{y=0}^2 = 1$$

Für $D \subset \mathbb{R}^2$ und $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ ist $\int_D g(x) dx = \int_D g(x_1, x_2) dx_1 dx_2$ definiert durch:

$$\begin{aligned} \int_D g(x) dx &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_D(x_1, x_2) \cdot g(x_1, x_2) dx_1 dx_2, \mathbb{1}_D(x_1, x_2) \\ &= \begin{cases} 1 & (x_1, x_2) \in D \\ 0 & (x_1, x_2) \notin D \end{cases} \end{aligned}$$

Im Fall $D = \mathbb{R}^2$ schreibt man auch

$$\begin{aligned} \int g(x) dx &= \int g(x_1, x_2) dx_1 dx_2 = \int_{\mathbb{R}^2} g(x) dx \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x_1, x_2) dx_1 dx_2 \end{aligned}$$

.

Ist D ein zweidimensionales Intervall der Form $D = (a_1, b_1) \times (a_2, b_2)$, so ist:

$$\begin{aligned} \int_{(a_1, b_1) \times (a_2, b_2)} g(x) dx &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_D(x_1, x_2) \cdot g(x_1, x_2) dx_1 dx_2 \\ &= \int_{a_2}^{b_2} \int_{a_1}^{b_1} \mathbb{1}_D(x_1, x_2) \cdot g(x_1, x_2) dx_1 dx_2 = \int_{a_2}^{b_2} \int_{a_1}^{b_1} g(x_1, x_2) dx_1 dx_2 \end{aligned}$$

1.2 Rechenregeln

- Linearität

$$\forall \alpha, \beta \in \mathbb{R}, f, g : \mathbb{R}^2 \rightarrow \mathbb{R}, D \subset \mathbb{R}^2 : \int_D (\alpha \cdot f(x) + \beta \cdot g(x)) dx = \alpha \int_D f(x) dx + \beta \int_D g(x) dx$$

- Additivität bezüglich des Integrationsbereichs

Für disjunkte Mengen $D_1, D_2 \subset \mathbb{R}^2, D_1 \cap D_2 = \emptyset$ gilt:

$$\int_{D_1 \cup D_2} g(x) dx = \int_{D_1} g(x) dx + \int_{D_2} g(x) dx$$

1.3 Monotonie

$$\int_D f(x) dx \leq \int_D g(x) dx \quad \text{falls} \quad f(x) \leq g(x), \forall x \in D$$

$$\int_{D_1} g(x) dx \leq \int_{D_2} g(x) dx \quad \text{falls} \quad D_1 \subset D_2 \subset \mathbb{R}^2 \quad \text{und} \quad g(x) \geq 0, \forall x \in D_2$$

1.4 Vertauschbarkeit der Integrationsreihenfolge

$$\int_{a_2}^{b_2} \int_{a_1}^{b_1} g(x_1, x_2) dx_1 dx_2 = \int_{a_1}^{b_1} \int_{a_2}^{b_2} g(x_1, x_2) dx_2 dx_1, \quad -\infty \leq a_1 \leq b_1 \leq \infty, -\infty \leq a_2 \leq b_2 \leq \infty$$

Für Integranden der Form $g(x_1, x_2) = h_1(x_1, x_2)h_2(x_2)$ gilt:

$$\int_{a_2}^{b_2} \int_{a_1}^{b_1} h_1(x_1, x_2)h_2(x_2) dx_1 dx_2 = \int_{a_2}^{b_2} h_2(x_2) \int_{a_1}^{b_1} h_1(x_1, x_2) dx_1 dx_2$$

Für Integranden der Form $h_1(x_1)h_2(x_2)$ gilt:

$$\int_{a_2}^{b_2} \int_{a_1}^{b_1} h_1(x_1)h_2(x_2) dx_1 dx_2 = \int_{a_2}^{b_2} h_2(x_2) \int_{a_1}^{b_1} h_1(x_1) dx_1 dx_2 = \int_{a_1}^{b_1} h_1(x_1) dx_1 \int_{a_2}^{b_2} h_2(x_2) dx_2$$

Analoge Regeln und Bezeichnungen gelten für höherdimensionale Integrale. Zum Beispiel gilt für $g: \mathbb{R}^3 \rightarrow \mathbb{R}$ und $a_i \leq b_i, i = 1, 2, 3, \dots$

$$\int_{a_1}^{b_1} \int_{a_2}^{b_2} \int_{a_3}^{b_3} g(x_1, x_2, x_3) dx_1 dx_2 dx_3 = \int_{a_2}^{b_2} \int_{a_3}^{b_3} \int_{a_1}^{b_1} g(x_1, x_2, x_3) dx_2 dx_3 dx_1$$

Die Integration kann in beliebiger Reihenfolge durchgeführt werden.

Für $h_1, \dots, h_p: \mathbb{R}^1 \rightarrow \mathbb{R}^1$ gilt:

$$\int_{a_p}^{b_p} \cdots \int_{a_1}^{b_1} h_1(x_1) \cdots h_p(x_p) dx_1 \cdots dx_p = \int_{a_1}^{b_1} h_1(x_1) dx_1 \cdots \int_{a_p}^{b_p} h_p(x_p) dx_p$$

In Beispiel 2:

$$\int_0^2 \int_0^1 xy \, dx \, dy = \int_0^1 x \, dx \cdot \int_0^2 y \, dy = \frac{x^2}{2} \Big|_0^1 \frac{y^2}{2} \Big|_0^2 = \frac{1}{2} \cdot 2 = 1$$

Ist $X = (X_1, \dots, X_p)^T$ ein Zufallsvektor mit Dichte $f: \mathbb{R}^p \rightarrow \mathbb{R}$, dann gilt:

$$P(X \in D) = \int_D f(x) \, dx \quad \text{für } D \subset \mathbb{R}^p \quad \text{und} \quad \int f(x) \, dx = 1$$

Beispiel 3 : Sei $X = (X_1, X_2)^T$ Zufallsvektor mit Dichte

$$f(x_1, x_2) = \begin{cases} 1 & \text{falls } 0 \leq x_1 \leq 1, 0 \leq x_2 \leq 1 \\ 0 & \text{sonst} \end{cases}$$

also Gleichverteilung auf $[0, 1]^2$.

Berechne $P(X_1 \leq X_2)$.

Setze

$$D := \{(X_1, X_2)^T \in \mathbb{R}^2 : x_1 \leq x_2\}$$

Daher gilt

$$P(X_1 \leq X_2) = P(X \in D) = \int_D f(x) \, dx = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_D(x_1, x_2) f(x_1, x_2) \, dx_1 \, dx_2$$

($\mathbb{1}$ bezeichnet die Indikatorfunktion).

$$\int_0^1 \int_0^1 \mathbb{1}_D(x_1, x_2) f(x_1, x_2) \, dx_1 \, dx_2 = \int_0^1 x_2 \, dx_2 = \frac{x_2^2}{2} \Big|_0^1 = \frac{1}{2}$$

Die Indikatorfunktion kann nur die Werte 1 oder 0 annehmen und ist gleich 1, falls $0 \leq x_1 \leq x_2 \leq 1$ und gleich 0 sonst.

Sei X ein p -dimensionaler Zufallsvektor mit Dichte $f: \mathbb{R}^p \rightarrow \mathbb{R}$. Betrachte den partitionierten Vektor $X = (x_1, x_2)^T$ wobei X_1 k -dimensional und X_2 $p - k$ -dimensionale Zufallsvektoren sind, $1 \leq k \leq p - 1$.

X_1 hat die sogenannte **Randdichte**

$$f_{X_1}(x_1) = \int f(x_1, x_2) \, dx_2, \quad x_1 \in \mathbb{R}^k.$$

X p -dimensional. Dichte f .

$$X = (X_1, X_2)^T,$$

X_1 k -dimensional, X_2 $p-k$ -dimensional. X_1 hat die Randdichte:

$$f_{X_1}(x_1) = \int f(x_1, x_2) dx_2, x_1 \in \mathbb{R}^k.$$

X_2 hat die Randdichte

$$f_{X_2}(x_2) = \int f(x_1, x_2) dx_1, x_2 \in \mathbb{R}^{p-k}.$$

f heisst dann auch *gemeinsame Dichte*. Die Verteilungen von X_1 und X_2 heissen *Randverteilungen* (*Marginalverteilungen*).

Beweis f_{X_1} ist eine Dichte von X_1 , für den Fall $p = 2, k = 1$. Für jedes $x_1 \in \mathbb{R}$ gilt:

$$\begin{aligned} P(X_1 \leq x_1) &= P(X_1 \leq x_1, X_2 \in \mathbb{R}) = P(X \in (-\infty, x_1] \times \mathbb{R}) = \int_{(-\infty, x_1] \times \mathbb{R}} f(u) du \\ &= \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(u_1, u_2) du_2 du_1 = \int_{-\infty}^{x_1} f_{X_1}(u_1) du_1 \end{aligned}$$

Beispiel 4 $X = (X_1, X_2)^T$ habe die Dichte f aus Beispiel 3. $Y = (Y_1, Y_2)^T$ habe die Dichte $g(y_1, y_2) = \begin{cases} 1 + (2y_1 - 1)(2y_2 - 1), & (y_1, y_2) \in v \in [0, 1]^2 \\ 0 & \text{sonst} \end{cases}$.

Bestimme Randdichten f_{X_i}, g_{y_i}

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2) dx_2 = \begin{cases} 1, & x_1 \in [0, 1] \\ 0 & \text{sonst.} \end{cases}$$

$$f_{X_2}(x_2) = \begin{cases} 1, & x_1 \in [0, 1] \\ 0 & \text{sonst.} \end{cases}$$

$$g_{y_1}(y_1) = \int_{-\infty}^{\infty} g(y_1, y_2) dy_2$$

$$= \begin{cases} \int_0^1 1 + (2y_1 - 1)(2y_2 - 1) dy_2 = 1 + (2y_1 - 1)[y_2^2 - y_2]_0^1 = 1, & y_1 \in [0, 1] \\ 0 & \text{sonst} \end{cases}$$

analog folgt

$$g_{Y_2}(y_2) = \begin{cases} 1, & y_2 \in [0, 1] \\ 0 & \text{sonst.} \end{cases}$$

→ X_1, X_2, Y_1, Y_2 haben dieselben Randverteilungen, aber X und Y haben verschiedene Verteilungen.

Sei wieder $X = (X_1, X_2)^T$ p -dimensionaler Zufallsvektor mit Dichte $f : \mathbb{R}^p \rightarrow \mathbb{R}$. X_1 k -dimensionaler und X_2 $p - k$ -dimensionaler Zufallsvektor. Beschreibe die Verteilung von X_1 unter der Annahme, dass X_2 den festgehaltenen Wert x_2 annimmt - X bezeichnet hier eine Zufallsvariable, x ist deterministisch.

Für $x_2 \in \mathbb{R}^{p-k}$ ist die *bedingte Dichte* von X_1 gegeben $X_2 = x_2$ definiert durch

$$f_{X_1}(x_1 | X_2 = x_2) = \frac{f(x_1, x_2)}{f_{X_2}(x_2)}, \quad x_1 \in \mathbb{R}^k, \quad \text{falls } f_{X_2}(x_2) > 0.$$

Die bedingte Dichte von X_2 gegeben $X_1 = x_1$ ist

$$f_{X_2}(x_2 | X_1 = x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)}, \quad x_2 \in \mathbb{R}^{p-k}, \quad \text{falls } f_{X_1}(x_1) > 0.$$

X_1 und X_2 heißen (*stochastisch*) *unabhängig*, falls

$$f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2), \quad \forall x_1 \in \mathbb{R}^k, x_2 \in \mathbb{R}^{p-k}.$$

Falls X_1 und X_2 unabhängig sind, gilt für alle möglichen Werte die hier miteinander verglichen werden können, also für alle $x_1 \in \mathbb{R}^k$ mit der Eigenschaft, dass die bedingte Dichte definiert ist, also $f_{X_1}(x_1) > 0$:

$$f_{X_2}(x_2 | X_1 = x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)} = \frac{f_{X_1}(x_1)f_{X_2}(x_2)}{f_{X_1}(x_1)} = f_{X_2}(x_2)$$

Das heisst die bedingte Dichte von X_2 gegeben $X_1 = x_1$ hängt nicht von x_1 ab und ist gleich der Randdichte von X_2 .

Sind X_1, \dots, X_p Zufallsvariablen und f eine Dichte von $(X_1, \dots, X_p)^T$, dann sind (X_1, \dots, X_p) unabhängig, falls

$$f(x_1, \dots, x_p) = f_{X_1}(x_1) \cdots f_{X_p}(x_p), \quad \forall x_1, \dots, x_p \in \mathbb{R}.$$

Beispiel 5 $X = (X_1, X_2)^T$ sei Zufallsvektor mit Dichte

$$f(x_1, x_2) = \begin{cases} x_1 + x_2, & \text{für } 0 \leq x_1, x_2 \leq 1 \\ 0, & \text{sonst} \end{cases}.$$

Randdichte:

$$f_{X_1}(x_1) = \begin{cases} \int_0^1 x_1 + x_2 \, dx_2 = x_1 + [\frac{x_2^2}{2}]_0^1 = x_1 + \frac{1}{2}, & x_1 \in [0, 1] \\ 0, & \text{sonst.} \end{cases}$$

$$f_{X_2}(x_2) = \begin{cases} x_2 + \frac{1}{2}, & x_2 \in [0, 1] \\ 0, & \text{sonst.} \end{cases}$$

Es gilt also nicht $f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2) \forall x_1, x_2 \in \mathbb{R}$. das heisst X_1 und X_2 sind nicht unabhängig.

Bedingte Dichten: Für $x_2 \in [0, 1]$ ist

$$f_{X_1}(x_1 | X_2 = x_2) = \frac{f(x_1, x_2)}{f_{X_2}(x_2)} = \begin{cases} \frac{x_1 + x_2}{0.5 + x_2}, & x_1 \in [0, 1] \\ 0 & \text{sonst.} \end{cases}$$

Für $x_1 \in [0, 1]$ ist

$$f_{X_2}(x_2 | X_1 = x_1) = \begin{cases} \frac{x_1 + x_2}{x_1 + \frac{1}{2}}, & x_2 \in [0, 1] \\ 0, & \text{sonst.} \end{cases}$$

Für $0 \leq \alpha \leq \beta \leq 1$ und für $0 < \delta \leq \frac{1}{2}$ gilt:

$$P(\alpha \leq X_1 \leq \beta | \frac{1}{2} \leq X_2 \leq \frac{1}{2} + \delta) = \frac{P(\alpha \leq X_1 \leq \beta, \frac{1}{2} \leq X_2 \leq \frac{1}{2} + \delta)}{P(0.5 \leq X_2 \leq 0.5 + \delta)} = \frac{\int_{\alpha}^{\beta} \int_{\frac{1}{2}}^{\frac{1}{2} + \delta} f(x_1, x_2) \, dx_2 \, dx_1}{\int_{\frac{1}{2}}^{\frac{1}{2} + \delta} f_{X_2}(x_2) \, dx_2}$$

$$= \frac{\int_{\alpha}^{\beta} \int_{\frac{1}{2}}^{\frac{1}{2} + \delta} x_1 + x_2 \, dx_2 \, dx_1}{\int_{\frac{1}{2}}^{\frac{1}{2} + \delta} 0.5 + x_2 \, dx_2} = \frac{\int_{\alpha}^{\beta} \delta x_1 + [\frac{x_2^2}{2}]_{x_2=0.5}^{0.5+\delta} \, dx_1}{\frac{\delta}{2} + [\frac{x_2^2}{2}]_{0.5}^{0.5+\delta}}$$

$$= \frac{\int_{\alpha}^{\beta} \delta x_1 + \frac{\delta}{2} + \frac{\delta^2}{2} \, dx_1}{\delta + \frac{\delta^2}{2}} = \frac{\int_{\alpha}^{\beta} x_1 + \frac{1}{2} \, dx_1 + \frac{\delta}{2}(\beta - \alpha)}{1 + \frac{\delta}{2}}$$

$$\rightarrow \lim_{\delta \rightarrow 0^+} P(\alpha \leq X_1 \leq \beta | 0.5 \leq X_2 \leq 0.5 + \delta) = \int_{\alpha}^{\beta} x_1 + 0.5 \, dx_1 = \int_{\alpha}^{\beta} f_{X_1}(x_1 | X_2 = 0.5) \, dx_1 \quad \blacksquare$$

Wichtige Parameter für univariate Verteilungen: Erwartungswert und Varianz. Entsprechende Parameter für multivariate Verteilungen ist der Vektor der Erwartungswerte und Kovarianzmatrix. Sei $X = (X_1, \dots, X_p)^T$ p -dimensionaler Zufallsvektor mit Dichte f .

$$E(X_1) = \int_{-\infty}^{\infty} x_1 f_{X_1}(x_1) dx_1 = \int_{-\infty}^{\infty} x_1 \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, \dots, x_p) dx_2 \dots dx_p dx_1 = \int x_1 f(X) dx.$$

Entsprechend ist der Erwartungswert von X_j

$$E(X_j) = \int_{-\infty}^{\infty} x_j f_{X_j} dx_j = \int x_j f(x_j) dx, \quad j = 1, \dots, p$$

Erwartungswert(-vektor) ist definiert durch $E(X) = (E(X_1), \dots, E(X_p))^T$.

Für $g: \mathbb{R}^p \rightarrow \mathbb{R}$ ist $E[g(X)] = \int g(x) f(x) dx$. Hierbei sind die Komponenten Vektoren, also:

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(x_1, \dots, x_p) f(x_1, \dots, x_p) dx_1 \dots dx_p.$$

Allgemeiner: Für matrixwertige Funktionen $G: \mathbb{R}^p \rightarrow \mathbb{R}^{n \times m}$:

$$G(x) = \begin{pmatrix} g_{11}(x) & \dots & g_{1m}(x) \\ \vdots & & \vdots \\ g_{n1}(x) & \dots & g_{nm}(x) \end{pmatrix}$$

ist $E[G(x)]$ komponentenweise definiert.

$$E[G(X)] = \begin{pmatrix} E[g_{11}(X)] & \dots & E[g_{1m}(X)] \\ \vdots & & \vdots \\ E[g_{n1}(X)] & \dots & E[g_{nm}(X)] \end{pmatrix} = (E[g_{ij}(X)])_{i=1, \dots, n, j=1, \dots, m}$$

Für matrixwertige Funktion $H: \mathbb{R}^p \rightarrow \mathbb{R}^{n \times m}$, $H(x) = (h_{ij}(x))_{i,j}$ ist $\int H(x) dx$ ebenfalls komponentenweise definiert.

$$\int H(x) dx = \begin{pmatrix} \int h_{11}(x) dx & \dots & \int h_{1m}(x) dx \\ \vdots & & \vdots \\ \int h_{n1}(x) dx & \dots & \int h_{nm}(x) dx \end{pmatrix}$$

Damit ergibt (G matrixwertig) sich

$$E[G(X)] = E[g_{ij}(X)]_{i,j} = \left(\int g_{ij}(x) f(x) dx \right)_{i,j} = \int G(x) f(x) dx$$

und insbesondere

$$E(X) = \int x f(x) dx$$

Beispiel 6 Berechne $E(X)$ für $X = (X_1, X_2)^T$ aus Beispiel 5.

$$\begin{aligned} E(X_1) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 f(x_1, x_2) dx_1 dx_2 = \int_0^1 \int_0^1 x_1 (x_1 + x_2) dx_1 dx_2 \\ &= \int_0^1 x_1^2 dx_1 + x_2 \int_0^1 x_1 dx_1 dx_2 = \int_0^1 \frac{1}{3} + x_2 \frac{1}{2} dx_2 = \frac{1}{3} + \frac{1}{2} \frac{1}{2} = \frac{7}{12} \end{aligned}$$

Daher

$$\begin{aligned} E(X_2) &= \dots = \frac{7}{12} \\ E(X) &= (E(X_1), E(X_2))^T = \left(\frac{7}{12}, \frac{7}{12}\right)^T. \end{aligned}$$

1.5 Rechenregeln

Für p -dimensionale Zufallsvektoren X, Y , $\alpha, \beta \in \mathbb{R}$, $g, h : \mathbb{R}^p \rightarrow \mathbb{R}^n$ gilt:

$$E[\alpha g(X) + \beta h(Y)] = \alpha E[g(X)] + \beta E[h(Y)]$$

$$E[AX + b] = AE(X) + b, \quad \text{wobei } A \in \mathbb{R}^{n \times p}, b \in \mathbb{R}^n$$

Ist $X = (X_1, X_2)^T$ mit X_1 k -dimensional und X_2 $p - k$ -dimensional und ist $g : \mathbb{R}^k \rightarrow \mathbb{R}$, dann

$$E[g(X_1)] = \int g(x_1) f(x) dx = \int g(x_1) f_{X_1}(x_1) dx_1.$$

Sind X_1 und X_2 unabhängig und $g : \mathbb{R}^k \rightarrow \mathbb{R}$, $h : \mathbb{R}^{p-k} \rightarrow \mathbb{R}$, dann

$$E[g(X_1)h(X_2)] = E[g(X_1)]E[h(X_2)]$$

Nachweis für den Fall $p = 2, k = 1$:

$$\begin{aligned} E[g(X_1)h(X_2)] &= \int \int g(x_1)h(x_2)f(x_1, x_2) dx_1 dx_2 \\ &= \int \int g(x_1)h(x_2)f_{X_1}(x_1)f_{X_2}(x_2) dx_1 dx_2 = \int g(x_1)f_{X_1}(x_1) dx_1 \int h(x_2)f_{X_2}(x_2) dx_2 \\ &= E[g(X_1)]E[h(X_2)] \blacksquare \end{aligned}$$

Sind X, Y p -dimensionale unabhängige Zufallsvektoren, dann gilt

$$E(XY^T) = E(X)E(Y)^T \quad \text{und} \quad E(X^T Y) = E(X)^T E(Y)$$

denn mit $X = (X_1, \dots, X_p)^T$, $Y = (Y_1, \dots, Y_p)^T$ ist

$$E(XY^T) = \begin{pmatrix} E(X_1) \\ \vdots \\ E(X_p) \end{pmatrix} (Y_1 \dots Y_p) = (E(X_j Y_k))_{j,k=1,\dots,p} = (E(X_j)E(Y_k))_{j,k=1,\dots,p}$$

$$\begin{pmatrix} E(X_1) \\ \vdots \\ E(X_p) \end{pmatrix} (E(X_1), \dots, E(X_p)) = E(X)E(X)^T$$

$$E(X^T Y) = E\left(\sum_{j=1}^p X_j Y_j\right) = \sum_{j=1}^p E(X_j)E(Y_j) = E(X)^T E(Y) \blacksquare$$

Einschub für Übungsblatt, Kovarianz:

$$\text{Cov}(X_j, X_k) := E[(X_j - E(X_j))(X_k - E(X_k))]$$

Sei $X = (X_1, \dots, X_p)^T$ p -dimensionaler Zufallsvektor und $\mu = (\mu_1, \dots, \mu_p) = E(X)$. (Alle μ s unten sind eigentlich μ)

Varianz von X_j :

$$\sigma_j^2 = \text{Var}(X_j) = E[(X_j - \mu_j)^2]$$

ist ein Maß für die Streuung von X_j .

Kovarianz zwischen X_j und X_k

$$\sigma_{jk}^2 = \text{Cov}(X_j, X_k) = E[(X_j - \mu_j)(X_k - \mu_k)]$$

ist ein Maß für den Zusammenhang zwischen X_j und X_k , $j \neq k$, ($\sigma_{jj} = \sigma_j^2$).

$$\text{Cov}(X_j, X_k) \geq 0 :$$

X_j und X_k weisen tendenziell einen gleichsinnigen linearen Zusammenhang auf.

$$\text{Cov}(X_j, X_k) \leq 0 :$$

Sind X_j und X_k unabhängig gilt:

$$\text{Cov}(X_j, X_k) = E(X_j - \mu_j)E(X_k - \mu_k) = 0.$$

Aus $\text{Cov}(X_j, X_k) = 0$ folgt im allg. nicht, dass X_j und X_k unabhängig sind, siehe Aufgabe 2, Blatt 1.

Die **Kovarianzmatrix** Σ der Zufallsvariable X ist definiert durch

$$\Sigma = \text{Var}(X) = E[(X - \mu)(X - \mu)^T]$$

$$\Sigma = (E[(X_j - \mu_j)(X_k - \mu_k)^T])_{j,k=1,\dots,p}$$

$$= \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2p} \\ \vdots & & \ddots & \\ \sigma_{p1} & & \dots & \sigma_p^2 \end{pmatrix}$$

Allgemeiner: Ist $X = (X_1, \dots, X_p)^T$ ein p -dimensionaler und $Y = (Y_1, \dots, Y_q)^T$ ein q -dimensionaler Zufallsvektor dann heißt

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))^T]$$

die Kovarianzmatrix von X und Y . In Position (j, k) von $\text{Cov}(X, Y)$ steht

$$E[(X_j - E(X_j))(Y_k - E(Y_k))] = \text{Cov}(X_j, Y_k)$$

also

$$\text{Cov}(X, Y) = (\text{Cov}(X_j, Y_k))_{j=1,\dots,p, k=1,\dots,q}$$

Lemma 7 Sei X ein p -dimensionaler, Y ein q -dimensionaler Zufallsvektor.

1. $\text{Cov}(X, X) = \text{Var}(X)$
2. $\text{Cov}(X, Y) = E(XY^T) - E(X)[E(Y)]^T$, $\text{Var}(X) = E(XX^T) - E(X)(E(X))^T$
3. $\text{Var}(a^T X) = a^T \text{Var}(X) a$ für $a \in \mathbb{R}^p$
4. $\text{Var}(AX + b) = A \text{Var}(X) A^T$ für $a \in \mathbb{R}^{n \times p}$, $b \in \mathbb{R}^n$
5. Sei $p = q$. Dann gilt $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + \text{Cov}(X, Y) + \text{Cov}(Y, X)$. Falls X und Y unabhängig sind, dann $\text{Cov}(X, Y) = \text{Cov}(Y, X) = 0$ und $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.
6. $\text{Var}(X)$ ist symmetrisch und nicht-negativ definit, d.h. $a^T \text{Var}(X) a \geq 0$, $\forall a \in \mathbb{R}^p$

Beweis Setze $\mu = E(X)$, $v = E(Y)$

1. $\text{Cov}(X, Y) = E[(X - \mu)(X - \mu)^T] = \text{Var}(X)$
2. $\text{Cov}(X, Y) = E[(X - \mu)(Y - v)^T] = E(XY^T - \mu Y^T - Xv^T + \mu v^T) = E(XY^T) - \mu E(Y^T) - E(X)v^T + \mu v^T = E(XY^T - E(X)(E(Y))^T)$. Daraus folgt mit (a), dass $\text{Var}(X) = \text{Cov}(X, X) = E(XX^T) - E(X)(E(X))^T$
3. Spezialfall von (d) mit $A = a^T$, $b = 0$
4. $\text{Var}(AX + b) = E[(AX + b - E(AX + b))(AX + b - E(AX + b))^T] = AE[(X - E(X))(X - E(X))^T A^T] = A\text{Var}(X)A^T$
5. $\text{Var}(X + Y) = E[(X + Y)(X + Y)^T] - (E(X + Y))^T = E(XX^T) + E(XY^T) + E(YX^T) + E(YY^T) - E(X)(E(X))^T - E(X)(E(Y))^T - E(Y)(E(X))^T - E(Y)(E(Y))^T = \text{Var}(X) + \text{Cov}(X, Y) + \text{Cov}(Y, X) + \text{Var}(Y)$. Sind $X = (X_1, \dots, X_p)^T$ und $Y = (Y_1, \dots, Y_p)^T$ unabhängig, dann gilt $E(X_j, Y_k) = E(X_j)E(Y_k)$ also $\text{Cov}(X_j, Y_k) = 0$. Daraus folgt $\text{Cov}(X, Y) = 0$, $\text{Cov}(Y, X) = 0$.
6. $\{\text{Var}(X)\}_{jk} = \text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j) = \{\text{Var}(X)\}_{kj}$ für alle $j, k = 1, \dots, p$. D.h. $\text{Var}(X)$ ist symmetrisch. Für alle Vektoren $a^T \in \mathbb{R}^p$ gilt $a^T \text{Var}(X) a = \text{Var}(a^T X) \geq 0$ (wegen c).

Beispiel 8 Sei $X = (X_1, X_2)$ wie in Bsp. 5. Berechne (i) $\text{Var}(X)$, (ii) $\text{Var}(X_1 - 3X_2)$, (iii) $\text{Var}(X_1 + X_2 + 1, 2X_1 - X_2 - 1)^T$.

1. $E(X_1) = E(X_2) = \frac{7}{12}$ nach Bsp. 6.

$$E(X_1^2) = \int x_1^2 f_{X_1}(x_1) dx = \int_0^1 x_1^2 (x_1 + \frac{1}{2}) dx = \frac{x_1^4}{4} \Big|_0^1 + \frac{x_1^3}{6} \Big|_0^1 = \frac{1}{4} + \frac{1}{6} = \frac{5}{12}$$

$$\Rightarrow \text{Var}(X_1) = E(X_1^2) - (E(X_1))^T = \frac{5}{12} - \left(\frac{7}{12}\right)^T = \frac{11}{144} \quad \text{ebenso} \quad \text{Var} X_2 = \frac{11}{144}.$$

$$\begin{aligned} E(X_1 X_2) &= \iint x_1 x_2 f(x_1, x_2) dx_1 dx_2 = \int_0^1 \int_0^1 x_1 x_2 f(x_1, x_2) dx_1 dx_2 \\ &= \int_0^1 x_1^2 dx \int_0^1 x_2 dx_2 + \int_0^1 x_1 dx_1 \int_0^1 x_2^2 dx_2 = \frac{1}{3} \frac{1}{2} + \frac{1}{2} \frac{1}{3} = \frac{1}{3} \end{aligned}$$

$$\text{Cov}(X_1, X_2) = E(X_1 X_2) - E(X_1)E(X_2) = \frac{1}{3} - \frac{7}{12} \cdot \frac{7}{12} = -\frac{1}{144} \Rightarrow \text{Var}(X)$$

$$\begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) \end{pmatrix} = \begin{pmatrix} \frac{11}{144} & -\frac{11}{144} \\ -\frac{11}{144} & \frac{11}{144} \end{pmatrix}$$

2. Mit $a = (1, -3)^T$ ist $X_1 - 3X_3 = a^T X \implies \text{Var}(X_1 - 3X_3) = \text{Var}(a^T X) = a^T \text{Var}(X) a$.

Einsetzen liefert $\frac{29}{36}$.

3. Mit $A = \begin{pmatrix} 1 & 1 \\ 2 & -1 \end{pmatrix}$ und $b = (1, -1)^T$ ist $AX + b = \begin{pmatrix} X_1 + X_2 + 1 \\ 2X_1 - X_2 - 1 \end{pmatrix} \implies \text{Var}(AX + b) = A \text{Var}(X) A^T$

Übungsblatt 1

Aufgabe 1

a)

$$f_{X_1}(x_1) = \int_0^1 f(x_1, x_2) dx_2 = 4x_1 e^{-x_1^2} \int_0^1 x_2 dx_2 = x_1 e^{-x_1^2}, \quad x_1 \geq 0.$$

$$f_{X_1}(x_1) = 0, \quad x_1 < 0$$

b)

$$f_{X_1}(x_2) = \int_0^\infty f(x_1, x_2) dx_1 = 4x_2 \int_0^\infty x_1 e^{-x_1^2} dx_1 = -\frac{e^{-x_1^2}}{2} \Big|_0^\infty = 2x_2, \quad x_2 \in [0, 1]$$

$$\Rightarrow f_{X_1}(x_1 | X_2 = \frac{1}{2}) = \frac{f(x_1, \frac{1}{2})}{f_{X_2}(\frac{1}{2})} = 2x_1 e^{-x_1^2}, \quad x_1 \geq 0, x_1 < 0.$$

c)

$$\begin{aligned} E(X_1) &= \int_0^\infty x_1 f_{X_1}(x_1) dx_1 \underbrace{=}_{a)} 2 \int_0^\infty x_1^2 e^{-x_1^2} dx_1 \\ &= \int_{-\infty}^\infty x_1^2 e^{-x_1^2} dx_1 \underbrace{=}_{x_1 = \frac{t^2}{2}} \int_{-\infty}^\infty \frac{t^2}{2} e^{-\frac{t^2}{2}} \frac{1}{\sqrt{2}} dt = \frac{\sqrt{\pi}}{2} \int_{-\infty}^\infty t^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \frac{\sqrt{\pi}}{2} \end{aligned}$$

$$E(X_2) = \int_0^1 x_2 f_{X_2}(x_2) dx_2 \underbrace{=}_{b)} \int_0^1 2x_2^2 dx_2 = \frac{2}{3} \Rightarrow E(X) = \left(\frac{\sqrt{\pi}}{2}, \frac{2}{3} \right)^T$$

d) Nach a), b) gilt

$$f_{X_1} f_{X_2} = f(x_1, x_2) \quad \forall x_1, x_2 \in \mathbb{R} \quad \Rightarrow \quad X_1, X_2 \quad \text{sind unabhängig.} \quad \text{Cov}(X_1, X_2) = 0.$$

e)

$$P(X_1 > X_2) = \int_0^1 \int_{x_2}^\infty f(x_1, x_2) dx_1 dx_2 = \int_0^1 4x_2 \int_{x_2}^\infty x_1 e^{-x_1^2} dx_1 dx_2$$

$$= \int_0^1 4x_2 - \frac{e^{-x_1^2}}{2} \Big|_{x_1=x_2}^{\infty} dx_2 = \int_0^1 4x_2 \frac{e^{-x_2^2}}{2} dx_2 = -e^{-x_2^2} \Big|_0^1 = 1 - e^{-1}$$

Aufgabe 2

a)

$$\begin{aligned} 1 &= c \int_{-1}^1 \int_{-1}^1 1^1 x_1^2 x_2^2 dx_1 dx_2 = \int_{-1}^1 1^1 \frac{2}{3} + 2x_2^2 dx_2 \\ &= c \left(\frac{4}{3} + \frac{4}{3} \right) = \frac{8c}{3} \implies c = \frac{3}{8} \end{aligned}$$

b)

Für $x_1 \in [-1, 1]$ gilt

$$f_{X_1}(x_1) = \int_{-1}^1 f(x_1, x_2) dx_2 = c \int_{-1}^1 x_1^2 + x_2^2 dx_2 = c(2x_1^2 + \frac{2}{3})$$

$$f_{X_2}(x_2|X_1 = x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)} = \frac{c(x_1^2 + x_2^2)}{c(2x_1^2 + \frac{2}{3})} = \frac{x_1^2 + x_2^2}{2x_1^2 + \frac{2}{3}} \quad \text{falls } x_2 \in [-1, 1]$$

$$f_{X_2}(x_2|X_1 = x_1) = 0 \quad \text{für } x_2 \in \mathbb{R} \setminus [-1, 1]$$

c)

$$E(X_1) = \int_{-1}^1 x_1 f_{X_1}(x_1) dx_1 \underbrace{=}_{b)} = c \int_{-1}^1 2x_1^3 + \frac{2x_1}{3} dx_1 = 0 \quad E(X_2) = 0 \quad \text{analog.}$$

$$\text{Cov}(X_1, X_2) = E(X_1 X_2) = c \int_{-1}^1 \int_{-1}^1 x_1 x_2 (x_1^2 + x_2^2) dx_1 dx_2$$

$$= c \int_{-1}^1 \int_{-1}^1 \underbrace{x_1^3 x_2 + x_1 x_2^3}_{\text{ungerade Funktion von } x_1} dx_1 dx_2 = 0$$

d) X_1 und X_2 sind nicht unabhängig, denn nach b) ist die bedingte Dichte der zweiten Variable $f_{X_2}(x_2|X_1 = x_1)$ nicht unabhängig von x_1 .

Aufgabe 3

Für $j = 1, \dots, p$ und alle $x_j \in \mathbb{R}$ gilt:

$$\begin{aligned} f_{X_j}(x_j) &= \int \cdots \int f(x_1, \dots, x_p) dx_1 \dots dx_{j-1} dx_{j+1} \dots dx_p \\ &= \int \cdots \int h_1(x_1) \cdots h_p(x_p) dx_1 \dots dx_{j-1} dx_{j+1} \dots dx_p \\ &= h_j(x_j) = \prod_{i \neq j} \int h_i(x_i) dx_i \implies f_{X_j}(x_j) = c_j h_j(x_j) \quad \text{für eine Konstante } c_j \end{aligned}$$

Wegen $1 = \int f_{X_j}(x_j) dx_j = c_j \int h_j(x_j) dx_j$ ist $c_j = \frac{1}{\int h_j(x_j) dx_j}$.

Für alle $x_1, \dots, x_p \in \mathbb{R}$ gilt:

$$\begin{aligned} f_{X_1}(x_1), \dots, f_{X_p}(x_p) &= \frac{h_1(x_1)}{\int h_1(u_1) du_1} \cdots \frac{h_p(x_p)}{\int h_p(u_p) du_p} \\ &= \frac{f(x_1, \dots, x_p)}{\int \cdots \int h_1(u_1) \cdots h_p(u_p) du_1 \dots du_p} = \frac{f(x_1, \dots, x_p)}{\int \cdots \int f(u_1, \dots, u_p) du_1 \dots du_p} = f(x_1, \dots, x_p) \end{aligned}$$

Daher sind X_1, \dots, X_p unabhängig.

$\text{Cov}(X, Y)$ ist ein Maß für den linearen Zusammenhang zwischen den beiden Zufallsvariablen X und Y . Der Wert ist aber schwer interpretierbar, denn er ist maßstabsabhängig.

$$\text{Cov}(aX, bY) = ab\text{Cov}(X, Y) \quad \forall a, b \in \mathbb{R}$$

Man verwendet daher ein standardisiertes Zusammenhangsmaß, nämlich den Korrelationskoeffizienten. Der *Korrelationskoeffizient* von Zufallsvariablen X und Y ist definiert durch $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$, sofern $\text{Var}(X), \text{Var}(Y) > 0$.

$(\text{Var}(X) = 0 \iff P(X = c) = 1 \text{ für ein } c \in \mathbb{R})$. ρ ist maßstabsunabhängig:

$$\rho(aX, bY) = \frac{ab\text{Cov}(X, Y)}{\sqrt{a^2\text{Var}(X)b^2\text{Var}(Y)}} = \frac{a}{|a|} \frac{b}{|b|} \rho(X, Y), \quad a, b \neq 0$$

Vorzeichen können sich jedoch ändern.

Satz 9 X und Y seien Zufallsvariablen mit $\text{Var}(X) > 0$ und $\text{Var}(Y) > 0 \implies -1 \leq \rho(X, Y) \leq 1$.

$$\rho(X, Y) = 1 \iff \exists \alpha > 0, \beta \in \mathbb{R} \text{ so dass } P(Y = \alpha X + \beta) = 1$$

$$\rho(X, Y) = -1 \iff \exists \alpha < 0, \beta \in \mathbb{R} \text{ so dass } P(Y = \alpha X + \beta) = 1$$

Lemma 10 *Cauchy-Schwarz Ungleichung.*

Für Zufallsvariablen X und Y gilt $(E(XY))^2 \leq E(X^2)E(Y^2)$ und

$$(E(XY))^2 = E(X^2)E(Y^2) \iff \exists a, b \neq 0 \in \mathbb{R} : P(aX = bY) = 1$$

Beweis Setze $\alpha = E(Y^2)\beta = E(XY)$.

Behauptung klar, falls $\alpha = 0$, da dann $P(Y = 0) = 1$ und $(E(XY)) = 0 = E(X^2)E(Y^2)$ und es gilt $P(aX = bY) = 1$ mit $a = 0, b = 1$.

Sei nun α nicht degeneriert, also $\alpha \geq 0$.

$$\begin{aligned} 0 \leq E[(\alpha X - \beta Y)^2] &= \alpha^2 E(X^2) - 2\alpha\beta \underbrace{E(XY)}_{=\beta} + \beta^2 \underbrace{E(Y^2)}_{=\alpha} \\ &= \alpha^2 E(X^2) - \alpha\beta^2 = \alpha(E(Y^2)E(X^2) - (E(XY))^2) \underbrace{\implies}_{\alpha > 0} (E(XY))^2 \leq E(X^2)E(Y^2) \end{aligned}$$

Falls $(E(XY))^2 = E(X^2)E(Y^2)$, dann

$$E[(\alpha X - \beta Y)^2] = 0 \implies P(\alpha X - \beta Y = 0) = 1 \quad \text{also} \quad P(aX = bY) = 1 \quad \text{mit} \quad a = \alpha \neq 0, b = \beta$$

Falls $P(aX = bY) = 1$ mit z.B. $a \neq 0$ dann $P(X = \frac{b}{a}Y) = 1$ und

$$(E(XY))^2 = (E(\frac{b}{a}Y^2))^2 = \frac{b^2}{a^2}E(Y^2)E(Y^2) = E(X^2)E(Y^2)$$

Erinnerung Satz 9 und Lemma 10:

$$-1 \leq \rho(X, Y) \leq 1$$

Cauchy Schwarz:

$$(E(XY))^2 \leq E(X^2)E(Y^2)$$

X und Y seien Zufallsvariablen mit $\text{Var}(X) > 0, \text{Var}(Y) > 0$

$$(\rho(X, Y))^2 = \frac{\text{Cov}(X, Y)^2}{\text{Var}(X)\text{Var}(Y)} = \frac{(E[(X - E(X))(Y - E(Y))])^2}{\text{Var}(X)\text{Var}(Y)}$$

$$\underbrace{\leq}_{\text{Lemma 10}} \frac{E[(X - E(X))^2]E[(Y - E(Y))^2]}{\text{Var}(X)\text{Var}(Y)} = 1$$

$$|\rho(X, Y)| = 1 \underbrace{\implies}_{\text{Lemma 10}} \exists a, b \in \mathbb{R}, \text{ nicht beide } = 0, \text{ mit}$$

$$(*) P(a - (X - E(X)) = b(Y - E(Y))) = 1$$

Hier muss zusätzlich $a \neq 0$ sein, denn sonst $P(Y = E(Y)) = 1$ im Widerspruch zu $\text{Var}(Y) > 0$. Ebenso muss $b \neq 0$ sein.

Also kann man (*) schreiben als

$$P(Y = \underbrace{\frac{a}{b}}_{\alpha} X - \underbrace{\frac{a}{b}E(X) + E(Y)}_{\beta})$$

Damit gezeigt

$$|\rho(X, Y) = 1| \implies \exists \alpha \neq 0, \beta \in \mathbb{R} \text{ mit } P(Y = \alpha X + \beta) = 1$$

Bzgl. Vorzeichen von α :

Falls $P(Y = \alpha X + \beta) = 1$ mit $\alpha \neq 0$, dann

$$\rho(X, Y) = \rho(X, \alpha X + \beta) = \rho(X, \alpha X) = \frac{\alpha}{|\alpha|} \frac{\text{Cov}(X, X)}{\text{Var}(X)} = \begin{cases} 1, & \alpha > 0 \\ -1, & \alpha < 0. \end{cases}$$

Beispiel 11 Betrachte zweimaligen Wurf einer Münze mit $P(\text{'Kopf'}) = p \in (0, 1)$.

Sei X die Anzahl Würfe, in denen Kopf fällt und Y der Rest. Berechnen nun $\rho(X, Y)$. Betrachte Erwartungswerte:

$$E(X) = 2p, \text{Var}(X) = 2p(1-p), E(Y) = 2(1-p), \text{Var}(Y) = 2p(1-p),$$

$$E(XY) = 1 \cdot P(X=1, Y=1) = 2p(1-p)$$

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 2p(1-p) - 4p(1-p) = -2p(1-p)$$

$$\Rightarrow \rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{-2p(1-p)}{2p(1-p)} = -1$$

Hier ist $P(X = \alpha X + \beta) = 1$ mit $\alpha = -1$ und $\beta = 2$.

Die *Korrelationsmatrix* eines Zufallsvektors $X(X_1, \dots, X_p)^T$ ist definiert durch die Matrix der einzelnen Korrelationskoeffizienten

$$P = (\rho_{jk})_{j,k=1,\dots,p}, \rho_{jk} = \rho(X_j, X_k).$$

sofern $\rho_j = \sqrt{\text{Var}(X_j)} > 0$ für alle $j = 1, \dots, p$.

P ist die Kovarianzmatrix des Vektors der standardisierten Zufallsvariablen $Z_j = \frac{X_j - E(X_j)}{\sigma_j}$.

Mit $\Delta = \text{diag}(\sigma_1, \dots, \sigma_p)$ gilt

$$P = \text{Var}((Z_1, \dots, Z_p)^T) = \text{Var}(\Delta^{-1}(X - E(X))) \underbrace{=}_{\text{Lemma 7}} \Delta^{-1} \text{Var}(X) \Delta^{-1}.$$

X_j und X_k heißen *unkorreliert*, falls $\rho(X_j, X_k) = 0$.

Satz 12 Transformationssatz für Dichten.

Sei X ein p -dimensionaler Zufallsvektor mit Dichte f_X (nicht Randdichte!).

Sei $T = \{x \in \mathbb{R}^p : f_X(x) > 0\}$ Träger von X und M sei eine offene Teilmenge von T mit $P(X \in M) = 1$.

Sei $h : M \rightarrow h(M) \subset \mathbb{R}^p$ eine bijektive Abbildung, stetig differenzierbar mit $J(x) = \det Dh(x) = \det \frac{\partial h_i(x)}{\partial x_j} \neq 0 \forall x \in M$. D ist Differentialoperator.

Dann hat $Y = h(X)$ die Dichte

$$f_Y(y) = \begin{cases} f_X(h^{-1}(y)) |\det(Dh^{-1}(y))| & y \in h(M) \\ 0 & \text{sonst.} \end{cases}$$

Beispiel 13 Log-Normalverteilung.

Sei $X \sim N(\mu, \sigma^2)$, also

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Hier ist $p = 1$, $T = \mathbb{R}$, $M = \mathbb{R}$, $h(x) = e^x$, $h(M) = (0, \infty)$, $h^{-1}(y) = \log y$, Funktionaldeterminante $J(x) = h'(x) = e^x \neq 0 \quad \forall x \in M$.

$\Rightarrow Y = h(X)$ hat die Dichte:

$$f_Y(y) = \frac{f_X(h^{-1}(y))}{|J(h^{-1}(y))|} = \frac{f_X(\log y)}{|J(\log y)|} = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log y - \mu)^2}{2\sigma^2}\right) \frac{1}{y}$$

Beispiel 14 Sei $X = (X_1, X_2)^T$ ein 2-dimensionaler Zufallsvektor mit Dichte f_X und es sei $T = \{x \in \mathbb{R}^2 : f_X(x) > 0\}$ offen.

Bestimme Dichte von $Y = \begin{pmatrix} X_1 + X_2 \\ X_1 - X_2 \end{pmatrix}$.

Setze $M = T$ und

$$h(x) = \begin{pmatrix} h_1(x) \\ h_2(x) \end{pmatrix} = \begin{pmatrix} x_1 + x_2 \\ x_1 - x_2 \end{pmatrix} \quad \text{für } x = (x_1, x_2)^T \in M$$

$$J(x) = \det\left(\frac{\partial h_i(x)}{\partial x_j}\right)_{i,j=1,2} = \det \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = 2 \neq 0$$

$$h(x) = (Y_1, Y_2)^T \iff \begin{cases} x_1 + x_2 = y_1 \\ x_1 - x_2 = y_2 \end{cases} \iff x_1 = \frac{y_1 + y_2}{2}, \quad x_2 = \frac{y_1 - y_2}{2}$$

Also

$$h^{-1}(y) = \begin{pmatrix} \frac{y_1 + y_2}{2} \\ \frac{y_1 - y_2}{2} \end{pmatrix}$$

Insbesondere ist $h : M \rightarrow h(M)$ bijektiv.

$\Rightarrow Y$ hat die Dichte

$$f_Y(y) = \begin{cases} \frac{f_X(h^{-1}(y))}{|J(h^{-1}(y))|} = \frac{1}{2} f_X\left(\frac{y_1 + y_2}{2}, \frac{y_1 - y_2}{2}\right), & y \in h(M) \\ 0 & \text{sonst.} \end{cases}$$

Falls $y \in \mathbb{R}^2 \setminus h(M)$, dann $h^{-1}(y) \in \mathbb{R}^2 \setminus M$, also $f_X(h^{-1}(y)) = 0$.

$$f_Y(y) = \frac{1}{2} f_X\left(\frac{Y_1 + Y_2}{2}, \frac{Y_1 - Y_2}{2}\right), \quad \forall y \in \mathbb{R}^2$$

Wichtiger Spezialfall: Sind X_1 und X_2 unabhängig, also

$$f_X(x) = f_{X_1}(x_1)f_{X_2}(x_2) \quad \text{für alle } x \in \mathbb{R}$$

Dann hat $X_1 + X_2$ die Dichte

$$\begin{aligned} f_{X_1+X_2}(z) &= f_{Y_1}(z) = \int_{-\infty}^{\infty} f_Y(z, y_2) dy_2 = \frac{1}{2} \int_{-\infty}^{\infty} f_X\left(\frac{t+y_2}{2}, \frac{z-y_2}{2}\right) dy_2 \\ &= \frac{1}{2} \int_{-\infty}^{\infty} f_{X_1}\left(\frac{z-y^2}{2}\right) f_{X_2}\left(\frac{z-y^2}{2}\right) dy_2 \underbrace{=}_{t=\frac{z+y_2}{2}} \frac{1}{2} \int_{-\infty}^{\infty} f_{X_1}(t) f_{X_2}\left(\frac{z-(2t-z)}{2}\right) 2 dt \\ &= \int_{-\infty}^{\infty} f_{X_1}(t) f_{X_2}(z-t) dt \end{aligned}$$

Dies nennt man Faltung von f_{X_1} und f_{X_2} .

Beispiel 15 Kunden erscheinen zu zufälligen Zeitpunkten in einem Laden.

Der erste Kunde erscheint zur Zeit X_1 . Die Zeitspanne zwischen dem Eintreffen von Kunde $i-1$ und Kunde i sei $X_i, i = 2, 3, \dots$

Dabei seien X_1, X_2, \dots unabhängige, exponentialverteilte Zufallsvariablen mit Erwartungswert $E[X_i] = \frac{1}{\lambda}, i = 1, 2, \dots$

Bestimme die gemeinsame Dichte der Ankunftszeiten T_1, \dots, T_n der ersten n Kunden

$$T_i = X_1 + \dots + X_i = \sum_i X_i.$$

X_i hat Dichte $f_{X_i}(x_i) = \lambda e^{-\lambda x_i}, x_i > 0$

$\Rightarrow X = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$ hat Dichte

$$f_X(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i) = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}, x_1, \dots, x_n > 0$$

$M = \{x \in \mathbb{R}^n : f_X(x) > 0\}$ ist offen.

$$T = \begin{pmatrix} T_1 \\ \vdots \\ T_n \end{pmatrix} = h(X) \quad \text{mit} \quad h_i(x_1, \dots, x_n) = x_1 + \dots, x_n$$

$$h(M) = \left\{ t = \begin{pmatrix} t_1 \\ \vdots \\ t_n \end{pmatrix} \in \mathbb{R}^n : 0 < t_1 < t_2 < \cdots < t_n \right\}$$

$$t = h(x) \Leftrightarrow t_j = \sum_{i=1}^j x_i, j = 1, \dots, n \Leftrightarrow x_1 = t_1 \wedge x_j = t_j - t_{j-1}, j = 2, \dots, n$$

Also

$$h^{-1}(t) = \begin{pmatrix} t_1 \\ t_2 - t_1 \\ \vdots \\ t_n - t_{n-1} \end{pmatrix}, J(x) = \det \left(\frac{\partial h_i(x)}{\partial x_j} \right)_{i,j=1,\dots,n} = \det \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 1 & 1 & 0 & \dots & 0 \\ \vdots & & & \ddots & \vdots \\ 1 & 1 & 1 & \dots & 1 \end{pmatrix} = 1 \neq 0$$

$$\Rightarrow \begin{pmatrix} T_1 \\ \vdots \\ T_n \end{pmatrix}$$

hat die Dichte:

$$f_T(t_1, \dots, t_n) = \frac{f_X(h^{-1}(t_1, \dots, t_n))}{|J(h^{-1}(t_1, \dots, t_n))|} = \lambda^n e^{-\lambda(t_1+t_2-t_1+\dots+t_n-t_{n-1})} = \lambda^n e^{-\lambda t_n}, 0 < t_1 < \dots < t_n$$

Sei $X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$ ein p -dimensionaler Zufallsvektor, wobei X_1 k -dimensional und X_2 $(p-k)$ -dimensional.

Der **bedingte Erwartungswert** von $g(X_1)$ gegeben $X_2 = x_2$ ist definiert durch:

$$E[g(X_1)|X_2 = x_2] = \int g(x_1) f_{X_1}(x_1|X_2 = x_2) dx_1$$

Analog berechnet man die **bedingte Kovarianzmatrix** $\text{Var}(X_1|X_2 = x_2)$ unter Verwendung der bedingten Dichte $f_{X_1}(x_1|X_2 = x_2)$.

Übungsblatt 2

Aufgabe 4

Zeigen Sie: Ist X eine $m \times n$ Zufallsmatrix und sind $A \in \mathbb{R}^{k \times n}, B \in \mathbb{R}^{m \times l}, C \in \mathbb{R}^{k \times l}$, dann gilt:

$$E[AXB + C] = AE[X]B + C$$

Sei

$$A = (a_{ij})_{i=1,\dots,k;j=1,\dots,n},$$

$$X = (x_{ij})_{i=1,\dots,m;j=1,\dots,n}, B = (b_{ij})_{i=1,\dots,m;j=1,\dots,l}, C = (c_{ij})_{i=1,\dots,k;j=1,\dots,l}.$$

$$\forall i = 1, \dots, k; j = 1, \dots, l: \{E[AXB + C]\}_{ij} = E[\{AXB + C\}_{ij}]$$

$$= E \left[\sum_{\mu=1}^n \sum_{\nu=1}^m a_{i\mu} x_{\mu\nu} b_{\nu j} + c_{ij} \right] = \sum_{\mu} \sum_{\nu} a_{i\mu} E[x_{\mu\nu}] b_{\nu j} + c_{ij} = AE[X]B + C_{ij}$$

Aufgabe 5

Es sei $X = (X_1, X_2, X_3)^T$ ein Zufallsvektor mit Kovarianzmatrix

$$\text{Var}(X) = \begin{pmatrix} 4 & 0 & -2 \\ 0 & 3 & 0 \\ -2 & 0 & 3 \end{pmatrix}$$

Berechnen Sie für jedes $\alpha \in \mathbb{R}$ den Korrelationskoeffizienten

$$\rho(\alpha X_1 - 7X_2 + X_3 + 2, \alpha X_1 + 7X_2 - X_3 - 2)$$

Setze

$$Y_1 = \alpha X_1 - 7X_2 + X_3 + 2, Y_2 = \alpha X_1 + 7X_2 - X_3 - 2, Y = \begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix}.$$

$$\begin{aligned} \text{Var}(Y) &= \text{Var} \left(\begin{pmatrix} \alpha & -7 & 1 \\ \alpha & 7 & -1 \end{pmatrix} X + \begin{pmatrix} 2 \\ -2 \end{pmatrix} \right) = \begin{pmatrix} \alpha & -7 & 1 \\ \alpha & 7 & -1 \end{pmatrix} \text{Var}(X) \begin{pmatrix} \alpha & \alpha \\ -7 & 7 \\ 1 & -1 \end{pmatrix} = \dots \\ &= \begin{pmatrix} 4\alpha^2 - 4\alpha + 150 & 4\alpha^2 - 150 \\ 4\alpha^2 + 4\alpha + 150 \end{pmatrix} = \begin{pmatrix} \text{Var}(Y_1) & \text{Cov}(Y_1, Y_2) \\ & \text{Var}(Y_2) \end{pmatrix} \end{aligned}$$

$$\rho(Y_1, Y_2) = \frac{\text{Cov}(Y_1, Y_2)}{\sqrt{\text{Var}(Y_1)\text{Var}(Y_2)}}$$

$$= \frac{4\alpha^2 - 150}{\sqrt{(4\alpha^2 - 4\alpha + 150)(4\alpha^2 + 4\alpha + 150)}} = \frac{2\alpha^2 - 75}{\sqrt{4\alpha^4 + 296\alpha^2 + 5625}}$$

Aufgabe 6

Betrachte Sie n Ehepaare und nehmen Sie an, dass jede der $2n$ Personen mit Wahrscheinlichkeit $p \in (0, 1)$ in 20 Jahren noch lebt (unabhängig von den anderen). Es sei X die Anzahl der in 20 Jahren noch lebenden Personen und Y sei die Anzahl der Ehepaare, bei denen in 20 Jahren sowohl die Frau als auch der Mann noch lebt. Berechnen Sie den Korrelationskoeffizienten von X und Y .

Seien $F_1, \dots, F_n, M_1, \dots, M_n$ unabhängige Bernoulli-Variablen.

$F_i = 1 \leftrightarrow$ Frau von Paar i lebt in 20 Jahren.

$M_i = 1 \leftrightarrow$ Mann von Paar i lebt in 20 Jahren.

$$P(F_i = 1) = P(M_i = 1) = p, i = 1, \dots, n$$

$$X = \sum_{i=1}^n F_i + \sum_{i=1}^n M_i, Y = \sum_{i=1}^n F_i M_i$$

$$X \sim \text{BIN}(2n, p) \Rightarrow E[X] = 2n \cdot p, \text{Var}(X) = 2n \cdot p \cdot (1 - p)$$

$$P(F_i M_i = 1) = P(F_i = 1)P(M_i = 1) = p^2$$

$$\Rightarrow Y \sim \text{BIN}(n, p^2) \Rightarrow E[Y] = n \cdot p^2, \text{Var}(Y) = n \cdot p^2 \cdot (1 - p^2)$$

$$E[XY] = E\left[\left(\sum_{i=1}^n F_i + \sum_{i=1}^n M_i\right)\left(\sum_{j=1}^n F_j M_j\right)\right] =$$

$$\begin{aligned} \sum_i \sum_j E[F_i F_j M_j] + E[M_i F_j M_j] &= \sum_i E[F_i^2 M_i] + E[M_i^2 F_i] + \sum_i \sum_{j \neq i} E[F_i F_j M_j] + E[M_i F_j M_j] \\ &= 2np^2 + 2n(n-1)p^3 \end{aligned}$$

Benutze dabei:

$$E[F_i^2 M_i] = E[F_i M_i] = E[F_i]E[M_i] = p^2 = E[M_i^2 F_i]$$

$$E[F_i F_j M_j] = E[F_i]E[F_j]E[M_j] = p^3 = E[M_i F_j M_j]$$

$$\begin{aligned} \Rightarrow \rho(X, Y) &= \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{E[XY] - E[X]E[Y]}{\sqrt{2np(1-p)n p^2(1-p^2)}} \\ &= \frac{2np^2 + 2n^2 p^3 - 2np^3 - 2n^2 p^3}{np\sqrt{2p(1-p)(1-p^2)}} = \frac{2p - 2p^2}{(1-p)\sqrt{2p(1+p)}} = \sqrt{\frac{2p}{1+p}} \end{aligned}$$

Aufgabe 7

Es seien X_1, \dots, X_n unabhängig, identisch verteilte p -dimensionale Zufallsvektoren mit $E[X_1] = \mu$ und $\text{Var}(X_1) = \Sigma$. Es sei

$$\bar{X} = \frac{1}{n} \sum_{j=1}^n X_j$$

$$S = \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X})(X_j - \bar{X})^T$$

Drücken Sie $E[\bar{X}]$, $\text{Var}(\bar{X})$ und $E[S]$ durch μ , Σ und n aus.

$$E[\bar{X}] = E\left[\frac{1}{n} \sum_j X_j\right] = \frac{1}{n} \sum_j E[X_j] = \frac{1}{n} \sum_j \mu = \mu$$

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_j X_j\right) = \frac{1}{n^2} \sum_j \text{Var}(X_j) = \frac{1}{n^2} \cdot n\Sigma = \frac{1}{n} \cdot \Sigma$$

$$\begin{aligned} E[S] &= E\left[\frac{1}{n} \sum_j (X_j - \bar{X})(X_j - \bar{X})^T\right] = \frac{1}{n} \cdot E\left[\left(\sum_j X_j X_j^T\right) - \bar{X} \left(\sum_j X_j^T\right) - \left(\sum_j X_j\right) \bar{X}^T + n\bar{X}\bar{X}^T\right] \\ &= \frac{1}{n} \cdot \sum_j E[X_j X_j^T] - E[\bar{X}\bar{X}^T] = \frac{1}{n} \sum_j (\text{Var}(X_j) + E[X_j] \cdot E[X_j^T]) - \text{Var}(\bar{X}) - E[\bar{X}] \cdot E^T[\bar{X}] \\ &= \Sigma + \mu\mu^T - \frac{1}{n}\Sigma - \mu\mu^T = \frac{n-1}{n}\Sigma \end{aligned}$$

Übungsblatt 3

Aufgabe 8

Es seien X_1 und X_2 unabhängige exponentialverteilte Zufallsvariablen mit Parameter $\lambda > 0$. Bestimmen Sie die gemeinsame Dichte von

$$Y_1 = X_1 + X_2, Y_2 = \frac{X_1}{X_2}$$

Sind Y_1 und Y_2 unabhängig?

Es seien X_i und T_i wie in Beispiel 15 der Vorlesung. Berechnen Sie für jedes $t > 0$

$$E[X_1 | X_2 = t]$$

Aufgabe 9

Der Zufallsvektor $X = (X_1, X_2, X_3)^T$ habe die Dichte

$$f(x_1, x_2, x_3) = \begin{cases} 2x_1(x_2 + x_3), & 0 \leq x_i \leq 1, i = 1, 2, 3 \\ 0, & \text{sonst} \end{cases}$$

(i)

Berechnen Sie für jedes $x_3 \in [0, 1]$

$$E\left[\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \mid X_3 = x_3\right]$$

(ii)

Berechnen Sie für jedes $x_3 \in [0, 1]$

$$\text{Var}\left[\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \mid X_3 = x_3\right]$$

$$X = (X_1, X_2)^T, E[g(X_1)|X_2 = x_2] = \int g(x_1) f_{X_1}(x_1|X_2 = x_2) dx_1$$

Die Funktion $x_2 \rightarrow E(X_1|X_2 = x_2)$ wird als Regressionsfunktion bezeichnet für die Regression von X_1 auf X_2 . Ist die Funktion von der Form $\alpha + \beta x_2$, so spricht man von linearer Regression.

Falls X_1 und X_2 unabhängig sind, dann gilt

$$E[g(X_1)|X_2 = x_2] = \int g(x_1) f_{X_1}(x_1|X_2 = x_2) dx_1 = \int g(x_1) f_{X_1}(x_1) dx_1 = E[g(X_1)] \quad \forall x_2$$

und die Regressionsfunktion ist konstant.

Beispiel 16 $(X_1, X_2)^T$ sei wie in Beispiel 5. Berechne Regressionsfunktion $E(X_1|X_2 = x_2)$ und $\text{Var}(X_1|X_2 = x_2)$, $0 \leq x_2 \leq 1$.

$$\begin{aligned} E(X_1|X_2 = x_2) &= \int x_1 f_{X_1}(x_1|X_2 = x_2) dx_1 = \int_0^1 x_1 \frac{x_1 + x_2}{0.5 + x_2} dx_1 \\ &= \frac{1}{0.5 + x_2} \int_0^1 x_1^2 + x_1 x_2 dx_1 = \frac{\frac{1}{3} + \frac{x_2}{2}}{0.5 + x_2} \\ E(X_1^2|X_2 = x_2) &= \frac{1}{0.5 + x_2} \int_0^1 x_1^3 + x_1^2 x_2 dx_1 = \frac{0.25 + \frac{x_2}{3}}{0.5 + x_2} \\ \Rightarrow \text{Var}(X_1|X_2 = x_2) &= \frac{\frac{1}{4} + \frac{x_2}{3}}{\frac{1}{2} + x_2} - \left(\frac{\frac{1}{3} + \frac{x_2}{2}}{0.5 + x_2}\right)^2 = \frac{1 + 6x_2 + 6x_2^2}{18(1 + 2x_2)^2} \end{aligned}$$

Sei $X = (X_1, X_2)^T$ p -dimensionaler Zufallsvektor mit Dichte f , X_1 k -dimensional, X_2 $(p - k)$ -dimensional.

Setze

$$\psi(x_2) = E(X_1|X_2 = x_2) \quad \forall x_2 \in \mathbb{R}^{p-k} : f_{X_2}(x_2) > 0$$

Der k -dimensionale Zufallsvektor $\psi(X_2)$ hat folgende Eigenschaften:

1. $E[\psi(X_2)] = E(X_1)$
2. $\psi(X_2)$ ist die beste Approximation von X_1 durch einen Zufallsvektor der Form $g(X_2)$ im Sinne der mittleren quadratischen Abweichung, d.h. für jede Funktion $g : \mathbb{R}^{p-k} \rightarrow \mathbb{R}^k$ gilt

$$E(\|X_1 - g(X_2)\|^2) \geq E(\|X_1 - \psi(X_2)\|^2) \quad \text{wobei} \quad \|u\| = \sqrt{u^T u} \quad \forall u \in \mathbb{R}^k$$

Begründung unter der Annahme $f_{X_2}(x_2) > 0 \quad \forall x_2 \in \mathbb{R}^{p-k}$.

1.

$$\begin{aligned} E[\psi(X_2)] &= \int \psi(x_2) f_{X_2}(x_2) dx_2 = \iint x_1 f_{X_1}(x_1|X_2 = x_2) dx_1 f_{X_2}(x_2) dx_2 \\ &= \iint \frac{x_1 f(x_1, x_2)}{f_{X_2}(x_2)} f_{X_2}(x_2) dx_1 dx_2 = \iint x_1 f(x_1, x_2) dx_1 dx_2 = E(X_1) \end{aligned}$$

2.

$$E(\|X_1 - g(X_2)\|^2) = E(\|X_1 - \psi(X_2) + \psi(X_2) - g(X_2)\|^2)$$

mit der Definition der euklidischen Norm folgt

$$\begin{aligned} &E(\|X_1 - \psi(X_2)\|^2) + E(\|\psi(X_2) - g(X_2)\|^2) + 2E[(X_1 - \psi(X_2))^T(\psi(X_2) - g(X_2))] \\ E[(X_1 - \psi(X_2))^T(\psi(X_2) - g(X_2))] &= \iint (x_1 - \psi(x_2))^T - (\psi(x_2) - g(x_2)) f(x_1, x_2) dx_1 dx_2 \\ &\quad \int \left[\int (x_1 - \psi(x_2)) f(x_1, x_2) dx_1 \right]^T (\psi(x_2) - g(x_2)) dx_2 \end{aligned}$$

und für jedes $x_2 \in \mathbb{R}^{p-k}$ gilt

$$\begin{aligned} \int (x_1 - \psi(x_2)) f(x_1, x_2) dx_1 &= \int x_1 f(x_1, x_2) dx_1 - \int \int t_1 f_{X_1}(t_1|X_2 = x_2) f(x_1, x_2) dx_1 \\ &\quad \underbrace{\int x_1 f(x_1, x_2) dx_1 - \int t_1 f_{X_1}(t_1|X_2 = x_2) \underbrace{\int f(x_1, x_2) dx_1}_{=f_{X_2}(x_2)} dt_1}_{=f(t_1, x_2)} = 0 \end{aligned}$$

$$\Rightarrow E(\|X_1 - g(X_2)\|^2) = E(\|X_1 - \psi(X_2)\|^2) + E(\|\psi(X_2) - g(X_2)\|^2) \geq E(\|X_1 - \psi(X_2)\|^2) \blacksquare$$

Der Zufallsvektor $\psi(X_2)$ wird auch mit $E(X_1|X_2)$ bezeichnet. Sind X_1 und X_2 unabhängig, dann gilt

$$\psi(x_2) = E(X_1|X_2 = x_2) = E(X_1)$$

also $E(X_1|X_2) = E(X_1)$.

2 Multivariate Normalverteilung

Lemma 17 Seien X_1, \dots, X_p unabhängige $\mathbb{N}(0, 1)$ verteilte Zufallsvariablen.

$$A \in \mathbb{R}^{p \times p} \text{ regulär}, b \in \mathbb{R}^p, X = (X_1, \dots, X_p)^T$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{p}{2}} \sqrt{\det B}} \exp\left(-\frac{1}{2}(y - b)^T B^{-1}(y - b)\right), y \in \mathbb{R}^p$$

wobei $B = AA^T$ und es gilt $E(Y) = b$, $\text{Var}(Y) = B$.

Beweis

X_i hat Dichte $f_{X_i}(x_i) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x_i^2}{2}}$ Daher hat X die Dichte

$$f_X(x) = \prod_{i=1}^p f_{X_i}(x_i) = \frac{1}{(2\pi)^{\frac{p}{2}}} e^{-\frac{1}{2} \sum_{i=1}^p x_i^2} = \frac{1}{(2\pi)^{\frac{p}{2}}} \exp\left(-\frac{1}{2} x^T x\right)$$

Wende Satz 1.12 an mit $h(x) = Ax + b$

$$h^{-1}(y) = A^{-1}(y - b), J(x) = |\det Dh(x)| = |\det A| \neq 0$$

Daher $Y = h(X)$ hat die Dichte

$$f_Y(y) = \frac{f_X(h^{-1}(y))}{|J(h^{-1}(y))|} = \frac{1}{(2\pi)^{\frac{p}{2}} |\det A|} \exp\left(-\frac{1}{2} (h^{-1}(y))^T h^{-1}(y)\right)$$

$$= \frac{1}{(2\pi)^{\frac{p}{2}} \sqrt{\det B}} \exp\left(-\frac{1}{2} (y - b)^T (A^{-1})^T A^{-1} (y - b)\right)$$

$$\underbrace{\hspace{10em}}_{B^{-1} = (AA^T)^{-1} = (A^T)^{-1} A^{-1} = (A^{-1})^T A^{-1}} \quad E(Y) = AE(X) + b = b$$

$$\text{Var}(Y) = A \text{Var}(X) A^T \underbrace{\hspace{10em}}_{\text{Var}(X) = \text{Einheitsmatrix}} \quad AA^T = B$$