

# 1 14.10.2013

Integrationstheorie in mehr als einer Dimension, Linearität von Integranden

## 16.10.2013

### 1.1 Monotonie

$$\int_D f(x) dx \leq \int_D g(x) dx \quad \text{falls} \quad f(x) \leq g(x), \forall x \in D$$

$$\int_{D_1} g(x) dx \leq \int_{D_2} g(x) dx \quad \text{falls} \quad D_1 \subset D_2 \subset \mathbb{R}^2 \quad \text{und} \quad g(x) \geq 0, \forall x \in D_2$$

### 1.2 Vertauschbarkeit der Integrationsreihenfolge

$$\int_{a_2}^{b_2} \int_{a_1}^{b_1} g(x_1, x_2) dx_1 dx_2 = \int_{a_1}^{b_1} \int_{a_2}^{b_2} g(x_1, x_2) dx_2 dx_1, \quad -\infty \leq a_1 \leq b_1 \leq \infty, -\infty \leq a_2 \leq b_2 \leq \infty$$

Für Integranden der Form  $g(x_1, x_2) = h_1(x_1)h_2(x_2)$  gilt:

$$\int_{a_2}^{b_2} \int_{a_1}^{b_1} h_1(x_1)h_2(x_2) dx_1 dx_2 = \int_{a_2}^{b_2} h_2(x_2) \int_{a_1}^{b_1} h_1(x_1) dx_1 dx_2$$

Für Integranden der Form  $h_1(x_1)h_2(x_2)$  gilt:

$$\int_{a_2}^{b_2} \int_{a_1}^{b_1} h_1(x_1)h_2(x_2) dx_1 dx_2 = \int_{a_2}^{b_2} h_2(x_2) \int_{a_1}^{b_1} h_1(x_1) dx_1 dx_2 = \int_{a_1}^{b_1} h_1(x_1) dx_1 \int_{a_2}^{b_2} h_2(x_2) dx_2$$

Analoge Regeln und Bezeichnungen gelten für höherdimensionale Integrale. Zum Beispiel gilt für  $g: \mathbb{R}^3 \rightarrow \mathbb{R}$  und  $a_i \leq b_i, i = 1, 2, 3, \dots$

$$\int_{a_1}^{b_1} \int_{a_2}^{b_2} \int_{a_3}^{b_3} g(x_1, x_2, x_3) dx_1 dx_2 dx_3 = \int_{a_2}^{b_2} \int_{a_3}^{b_3} \int_{a_1}^{b_1} g(x_1, x_2, x_3) dx_2 dx_3 dx_1$$

Die Integration kann in beliebiger Reihenfolge durchgeführt werden.

Für  $h_1, \dots, h_p : \mathbb{R}^1 \rightarrow \mathbb{R}^1$  gilt:

$$\int_{a_p}^{b_p} \cdots \int_{a_1}^{b_1} h_1(x_1) \cdots h_p(x_p) dx_1 \cdots dx_p = \int_{a_1}^{b_1} h_1(x_1) dx_1 \cdots \int_{a_p}^{b_p} h_p(x_p) dx_p$$

In Beispiel 2:

$$\int_0^2 \int_0^1 xy \, dx \, dy = \int_0^1 x \, dx \cdot \int_0^2 y \, dy = \frac{x^2}{2} \Big|_0^1 \frac{y^2}{2} \Big|_0^2 = \frac{1}{2} \cdot 2 = 1$$

Ist  $X = (X_1, \dots, X_p)^T$  ein Zufallsvektor mit Dichte  $f : \mathbb{R}^p \rightarrow \mathbb{R}$ , dann gilt:

$$P(X \in D) = \int_D f(x) \, dx \quad \text{für } D \subset \mathbb{R}^p \quad \text{und} \quad \int f(x) \, dx = 1$$

Beispiel 3: Sei  $X = (X_1, X_2)^T$  Zufallsvektor mit Dichte

$$f(x_1, x_2) = \begin{cases} 1 & \text{falls } 0 \leq x_1 \leq 1, 0 \leq x_2 \leq 1 \\ 0 & \text{sonst} \end{cases}$$

also Gleichverteilung auf  $[0, 1]^2$ .

Berechne  $P(X_1 \leq X_2)$ .

Setze

$$D := \{(X_1, X_2)^T \in \mathbb{R}^2 : x_1 \leq x_2\}$$

Daher gilt

$$P(X_1 \leq X_2) = P(X \in D) = \int_D f(x) \, dx = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathbb{1}_D(x_1, x_2) f(x_1, x_2) \, dx_1 \, dx_2$$

( $\mathbb{1}$  bezeichnet die Indikatorfunktion).

$$\int_0^1 \int_0^1 \mathbb{1}_D(x_1, x_2) f(x_1, x_2) \, dx_1 \, dx_2 = \int_0^1 x_2 \, dx_2 = \frac{x_2^2}{2} \Big|_0^1 = \frac{1}{2}$$

Die Indikatorfunktion kann nur die Werte 1 oder 0 annehmen und ist gleich 1, falls  $0 \leq x_1 \leq x_2 \leq 1$  und gleich 0 sonst.

Sei  $X$  ein  $p$ -dimensionaler Zufallsvektor mit Dichte  $f : \mathbb{R}^p \rightarrow \mathbb{R}$ . Betrachte den partitionierten Vektor  $X = (x_1, x_2)^T$  wobei  $X_1$   $k$ -dimensional und  $X_2$   $p - k$ -dimensionale Zufallsvektoren sind,  $1 \leq k \leq p - 1$ .

$X_1$  hat die sogenannte **Randdichte**

$$f_{X_1}(x_1) = \int f(x_1, x_2) \, dx_2, \quad x_1 \in \mathbb{R}^k.$$

## 2 21.10.2013

$X$  p-dimensional. Dichte  $f$ .

$$X = (X_1, X_2)^T$$

,  $X_1$  k-dimensional,  $X_2$  p-k-dimensional.  $X_1$  hat die Randdichte:

$$f_{X_1}(x_1) = \int f(x_1, x_2) dx_2, x_1 \in \mathbb{R}^k.$$

$X_2$  hat die Randdichte

$$f_{X_2}(x_2) = \int f(x_1, x_2) dx_1, x_2 \in \mathbb{R}^{p-k}.$$

$f$  heisst dann auch *gemeinsame Dichte*. Die Verteilungen von  $X_1$  und  $X_2$  heissen *Randverteilungen* (*Marginalverteilungen*).

**Beweis**  $f_{X_1}$  ist eine Dichte von  $X_1$ , für den Fall  $p = 2, k = 1$ . Für jedes  $x_1 \in \mathbb{R}$  gilt:

$$\begin{aligned} P(X_1 \leq x_1) &= P(X_1 \leq x_1, X_2 \in \mathbb{R}) = P(X \in (-\infty, x_1] \times \mathbb{R}) = \int_{(-\infty, x_1] \times \mathbb{R}} f(u) du \\ &= \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(u_1, u_2) du_2 du_1 = \int_{-\infty}^{x_1} f_{X_1}(u_1) du_1 \end{aligned}$$

**Beispiel 4**  $X = (X_1, X_2)^T$  habe die Dichte  $f$  aus Beispiel 3.  $Y = (Y_1, Y_2)^T$  habe die Dichte  $g(y_1, y_2) = \begin{cases} 1 + (2y_1 - 1)(2y_2 - 1), & (y_1, y_2) \in [0, 1]^2 \\ 0 & \text{sonst} \end{cases}$ .

Bestimme Randdichten  $f_{X_i}, g_{y_i}$

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2) dx_2 = \begin{cases} 1, & x_1 \in [0, 1] \\ 0 & \text{sonst.} \end{cases}$$

$$f_{X_2}(x_2) = \begin{cases} 1, & x_2 \in [0, 1] \\ 0 & \text{sonst.} \end{cases}$$

$$g_{y_1}(y_1) = \int_{-\infty}^{\infty} g(y_1, y_2) dy_2$$

$$= \begin{cases} \int_0^1 1 + (2y_1 - 1)(2y_2 - 1) dy_2 = 1 + (2y_1 - 1)[y_2^2 - y_2]_0^1 = 1, & y_1 \in [0, 1] \\ 0 & \text{sonst} \end{cases}$$

analog folgt

$$g_{y_2}(y_2) = \begin{cases} 1, & y_2 \in [0, 1] \\ 0 & \text{sonst.} \end{cases}$$

→  $X_1, X_2, Y_1, Y_2$  haben dieselben Randverteilungen, aber  $X$  und  $Y$  haben verschiedene Verteilungen.

Sei wieder  $X = (X_1, X_2)^T$   $p$ -dimensionaler Zufallsvektor mit Dichte  $f : \mathbb{R}^p \rightarrow \mathbb{R}$ .  $X_1$   $k$ -dimensionaler und  $X_2$   $p - k$ -dimensionaler Zufallsvektor. Beschreibe die Verteilung von  $X_1$  unter der Annahme, dass  $X_2$  den festgehaltenen Wert  $x_2$  annimmt -  $X$  bezeichnet hier eine Zufallsvariable,  $x$  ist deterministisch.

Für  $x_2 \in \mathbb{R}^{p-k}$  ist die *bedingte Dichte* von  $X_1$  gegeben  $X_2 = x_2$  definiert durch

$$f_{X_1}(x_1 | X_2 = x_2) = \frac{f(x_1, x_2)}{f_{X_2}(x_2)}, \quad x_1 \in \mathbb{R}^k, \quad \text{falls } f_{X_2}(x_2) > 0.$$

Die bedingte Dichte von  $X_2$  gegeben  $X_1 = x_1$  ist

$$f_{X_2}(x_2 | X_1 = x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)}, \quad x_2 \in \mathbb{R}^{p-k}, \quad \text{falls } f_{X_1}(x_1) > 0.$$

$X_1$  und  $X_2$  heißen (*stochastisch*) *unabhängig*, falls

$$f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2), \quad \forall x_1 \in \mathbb{R}^k, x_2 \in \mathbb{R}^{p-k}.$$

Falls  $X_1$  und  $X_2$  unabhängig sind, gilt für alle möglichen Werte die hier miteinander verglichen werden können, also für alle  $x_1 \in \mathbb{R}^k$  mit der Eigenschaft, dass die bedingte Dichte definiert ist, also  $f_{X_1}(x_1) > 0$ :

$$f_{X_2}(x_2 | X_1 = x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)} = \frac{f_{X_1}(x_1)f_{X_2}(x_2)}{f_{X_1}(x_1)} = f_{X_2}(x_2)$$

Das heisst die bedingte Dichte von  $X_2$  gegeben  $X_1 = x_1$  hängt nicht von  $x_1$  ab und ist gleich der Randdichte von  $X_2$ .

Sind  $X_1, \dots, X_p$  Zufallsvariablen und  $f$  eine Dichte von  $(X_1, \dots, X_p)^T$ , dann sind  $(X_1, \dots, X_p)$  unabhängig, falls

$$f(x_1, \dots, x_p) = f_{X_1}(x_1) \cdots f_{X_p}(x_p), \quad \forall x_1, \dots, x_p \in \mathbb{R}.$$

**Beispiel 5**

$X = (X_1, X_2)^T$  sei Zufallsvektor mit Dichte

$$f(x_1, x_2) = \begin{cases} x_1 + x_2, & \text{für } 0 \leq x_1, x_2 \leq 1 \\ 0, & \text{sonst} \end{cases}$$

Randdichte:

$$f_{X_1}(x_1) = \begin{cases} \int_0^1 x_1 + x_2 \, dx_2 = x_1 + \left[\frac{x_2^2}{2}\right]_0^1 = x_1 + \frac{1}{2}, & x_1 \in [0, 1] \\ 0, & \text{sonst.} \end{cases}$$

$$f_{X_2}(x_2) = \begin{cases} x_2 + \frac{1}{2}, & x_2 \in [0, 1] \\ 0, & \text{sonst.} \end{cases}$$

Es gilt also nicht  $f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2) \forall x_1, x_2 \in \mathbb{R}$ . das heisst  $X_1$  und  $X_2$  sind nicht unabhängig.

Bedingte Dichten: Für  $x_2 \in [0, 1]$  ist

$$f_{X_1}(x_1 | X_2 = x_2) = \frac{f(x_1, x_2)}{f_{X_2}(x_2)} = \begin{cases} \frac{x_1 + x_2}{0.5 + x_2}, & x_1 \in [0, 1] \\ 0 & \text{sonst.} \end{cases}$$

Für  $x_1 \in [0, 1]$  ist

$$f_{X_2}(x_2 | X_1 = x_1) = \begin{cases} \frac{x_1 + x_2}{x_1 + \frac{1}{2}}, & x_2 \in [0, 1] \\ 0, & \text{sonst.} \end{cases}$$

Für  $0 \leq \alpha \leq \beta \leq 1$  und für  $0 < \delta \leq \frac{1}{2}$  gilt:

$$P(\alpha \leq X_1 \leq \beta | \frac{1}{2} \leq X_2 \leq \frac{1}{2} + \delta) = \frac{P(\alpha \leq X_1 \leq \beta, \frac{1}{2} \leq X_2 \leq \frac{1}{2} + \delta)}{P(0.5 \leq X_2 \leq 0.5 + \delta)} = \frac{\int_{\alpha}^{\beta} \int_{\frac{1}{2}}^{\frac{1}{2} + \delta} f(x_1, x_2) \, dx_2 \, dx_1}{\int_{\frac{1}{2}}^{\frac{1}{2} + \delta} f_{X_2}(x_2) \, dx_2}$$

$$= \frac{\int_{\alpha}^{\beta} \int_{\frac{1}{2}}^{\frac{1}{2} + \delta} x_1 + x_2 \, dx_2 \, dx_1}{\int_{\frac{1}{2}}^{\frac{1}{2} + \delta} 0.5 + x_2 \, dx_2} = \frac{\int_{\alpha}^{\beta} \delta x_1 + \left[\frac{x_2^2}{2}\right]_{x_2=0.5}^{0.5+\delta} \, dx_1}{\frac{\delta}{2} + \left[\frac{x_2^2}{2}\right]_{0.5}^{0.5+\delta}}$$

$$= \frac{\int_{\alpha}^{\beta} \delta x_1 + \frac{\delta}{2} + \frac{\delta^2}{2} dx_1}{\delta + \frac{\delta^2}{2}} = \frac{\int_{\alpha}^{\beta} x_1 + \frac{1}{2} dx_1 + \frac{\delta}{2}(\beta - \alpha)}{1 + \frac{\delta}{2}}$$

$$\rightarrow \lim_{\delta \rightarrow 0^+} P(\alpha \leq X_1 \leq \beta \mid 0.5 \leq X_2 \leq 0.5 + \delta) = \int_{\alpha}^{\beta} x_1 + 0.5 dx_1 = \int_{\alpha}^{\beta} f_{X_1}(x_1 \mid X_2 = 0.5) dx_1 \quad \blacksquare$$

Wichtige Parameter für univariate Verteilungen: Erwartungswert und Varianz. Entsprechende Parameter für multivariate Verteilungen ist der Vektor der Erwartungswerte und Kovarianzmatrix. Sei  $X = (X_1, \dots, X_p)^T$   $p$ -dimensionaler Zufallsvektor mit Dichte  $f$ .

$$E(X_1) = \int_{-\infty}^{\infty} x_1 f_{X_1}(x_1) dx_1 = \int_{-\infty}^{\infty} x_1 \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_p) dx_2 \dots dx_p dx_1 = \int x_1 f(X) dx.$$

Entsprechend ist der Erwartungswert von  $X_j$

$$E(X_j) = \int_{-\infty}^{\infty} x_j f_{X_j} dx_j = \int x_j f(x_j) dx, \quad j = 1, \dots, p$$

Erwartungswert(-vektor) ist definiert durch  $E(X) = (E(X_1), \dots, E(X_p))^T$ .

Für  $g: \mathbb{R}^p \rightarrow \mathbb{R}$  ist  $E[g(X)] = \int g(x) f(x) dx$ . Hierbei sind die Komponenten Vektoren, also:

$$\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} g(x_1, \dots, x_p) f(x_1, \dots, x_p) dx_1 \dots dx_p.$$

Allgemeiner: Für matrixwertige Funktionen  $G: \mathbb{R}^p \rightarrow \mathbb{R}^{n \times m}$ :

$$G(x) = \begin{pmatrix} g_{11}(x) & \dots & g_{1m}(x) \\ \vdots & & \vdots \\ g_{n1}(x) & \dots & g_{nm}(x) \end{pmatrix}$$

ist  $E[G(x)]$  komponentenweise definiert.

### 3 23.10.13

$$E[G(X)] = \begin{pmatrix} E[g_{11}(X)] & \dots & E[g_{1m}(X)] \\ \vdots & & \vdots \\ E[g_{n1}(X)] & \dots & E[g_{nm}(X)] \end{pmatrix} = (E[g_{ij}(X)])_{i=1,\dots,n, j=1,\dots,m}$$

Für matrixwertige Funktion  $H : \mathbb{R}^p \rightarrow \mathbb{R}^{n \times m}$ ,  $H(x) = (h_{ij}(x))_{i,j}$  ist  $\int H(x) dx$  ebenfalls komponentenweise definiert.

$$\int H(x) dx = \begin{pmatrix} \int h_{11}(x) dx & \dots & \int h_{1m}(x) dx \\ \vdots & & \vdots \\ \int h_{n1}(x) dx & \dots & \int h_{nm}(x) dx \end{pmatrix}$$

Damit ergibt ( $G$  matrixwertig) sich

$$E[G(X)] = E[g_{ij}(X)]_{i,j} = \left( \int g_{ij}(x) f(x) dx \right)_{i,j} = \int G(x) f(x) dx$$

und insbesondere

$$E(X) = \int x f(x) dx$$

#### Beispiel 6

Berechne  $E(X)$  für  $X = (X_1, X_2)^T$  aus Beispiel 5.

$$\begin{aligned} E(X_1) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 f(x_1, x_2) dx_1 dx_2 = \int_0^1 \int_0^1 x_1 (x_1 + x_2) dx_1 dx_2 \\ &= \int_0^1 x_1^2 dx_1 + x_2 \int_0^1 x_1 dx_1 dx_2 = \int_0^1 \frac{1}{3} + x_2 \frac{1}{2} dx_2 = \frac{1}{3} + \frac{1}{2} \frac{1}{2} = \frac{7}{12} \end{aligned}$$

Daher

$$\begin{aligned} E(X_2) &= \dots = \frac{7}{12} \\ E(X) &= (E(X_1), E(X_2))^T = \left( \frac{7}{12}, \frac{7}{12} \right)^T \end{aligned}$$

.

#### Rechenregeln

Für  $p$ -dimensionale Zufallsvektoren  $X, Y$ ,  $\alpha, \beta \in \mathbb{R}$ ,  $g, h : \mathbb{R}^p \rightarrow \mathbb{R}^n$  gilt:

$$E[\alpha g(X) + \beta h(Y)] = \alpha E[g(X)] + \beta E[h(Y)]$$

$$E[AX + b] = AE(X) + b, \quad \text{wobei } A \in \mathbb{R}^{n \times p}, b \in \mathbb{R}^n$$

Ist  $X = (X_1, X_2)^T$  mit  $X_1$   $k$ -dimensional und  $X_2$   $p - k$ -dimensional und ist  $g : \mathbb{R}^k \rightarrow \mathbb{R}$ , dann

$$E[g(X_1)] = \int g(x_1) f(x) dx = \int g(x_1) f_{X_1}(x_1) dx_1.$$

Sind  $X_1$  und  $X_2$  unabhängig und  $g : \mathbb{R}^k \rightarrow \mathbb{R}$ ,  $h : \mathbb{R}^{p-k} \rightarrow \mathbb{R}$ , dann

$$E[g(X_1)h(X_2)] = E[g(X_1)]E[h(X_2)]$$

Nachweis für den Fall  $p = 2, k = 1$ :

$$\begin{aligned} E[g(X_1)h(X_2)] &= \int \int g(x_1)h(x_2)f(x_1, x_2) dx_1 dx_2 \\ &= \int \int g(x_1)h(x_2)f_{X_1}(x_1)f_{X_2}(x_2) dx_1 dx_2 = \int g(x_1)f_{X_1}(x_1) dx_1 \int h(x_2)f_{X_2}(x_2) dx_2 \\ &= E[g(X_1)]E[h(X_2)] \blacksquare \end{aligned}$$

Sind  $X, Y$   $p$ -dimensionale unabhängige Zufallsvektoren, dann gilt

$$E(XY^T) = E(X)E(Y)^T \quad \text{und} \quad E(X^TY) = E(X)^TE(Y)$$

denn mit  $X = (X_1, \dots, X_p)^T, Y = (Y_1, \dots, Y_p)^T$  ist

$$E(XY^T) = \begin{pmatrix} E(X_1) \\ \vdots \\ E(X_p) \end{pmatrix} (Y_1 \quad \dots \quad Y_n) = (E(X_j Y_k))_{j,k=1,\dots,p} = (E(X_j)E(Y_k))_{j,k=1,\dots,p}$$

$$\begin{pmatrix} E(X_1) \\ \vdots \\ E(X_p) \end{pmatrix} (E(X_1), \dots, E(Y_p)) = E(X)E(Y)^T$$

$$E(X^TY) = E\left(\sum_{j=1}^p X_j Y_j\right) = \sum_{j=1}^p E(X_j)E(Y_j) = E(X)^TE(Y) \blacksquare$$

Einschub für Übungsblatt, Kovarianz:

$$\text{Cov}(X_j, X_k) := E[X_j - E(X_j)(X_k - E(X_k))]$$



## 4 28.10.13

Sei  $X = (X_1, \dots, X_p)^T$   $p$ -dimensionaler Zufallsvektor und  $\mu = (\mu_1, \dots, \mu_p) = E(X)$ . (Alle  $p$ s unten sind eigentlich müss  $\mu$ )

Varianz von  $X_j$ :

$$\sigma_j^2 = \text{Var}(X_j) = E[(X_j - \mu_j)^2]$$

ist ein Maß für die Streuung von  $X_j$ .

Kovarianz zwischen  $X_j$  und  $X_k$

$$\sigma_{jk}^2 = \text{Cov}(X_j, X_k) = E[(X_j - \mu_j)(X_k - \mu_k)]$$

ist ein Maß für den Zusammenhang zwischen  $X_j$  und  $X_k$ ,  $j \neq k$ , ( $\sigma_{jj} = \sigma_j^2$ ).

$$\text{Cov}(X_j, X_k) \geq 0 :$$

$X_j$  und  $X_k$  weisen tendenziell einen gleichsinnigen linearen Zusammenhang auf.

$$\text{Cov}(X_j, X_k) \leq 0 :$$

Sind  $X_j$  und  $X_k$  unabhängig gilt:

$$\text{Cov}(X_j, X_k) = E(X_j - \mu_j)E(X_k - \mu_k) = 0.$$

Aus  $\text{Cov}(X_j, X_k) = 0$  folgt im allg. nicht, dass  $X_j$  und  $X_k$  unabhängig sind, siehe Aufgabe 2, Blatt 1.

Die **Kovarianzmatrix**  $\Sigma$  der Zufallsvariable  $X$  ist definiert durch

$$\Sigma = \text{Var}(X) = E[(X - \mu)(X - \mu)^T]$$

$$\Sigma = (E[(X_j - \mu_j)(X_k - \mu_k)^T])_{j,k=1,\dots,p}$$

$$= \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2p} \\ \vdots & & \ddots & \\ \sigma_{p1} & \dots & \dots & \sigma_p^2 \end{pmatrix}$$

Allgemeiner: Ist  $X = (X_1, \dots, X_p)^T$  ein  $p$ -dimensionaler und  $Y = (Y_1, \dots, Y_q)^T$  ein  $q$ -dimensionaler Zufallsvektor dann heißt

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))^T]$$

die Kovarianzmatrix von  $X$  und  $Y$ . In Position  $(j, k)$  von  $\text{Cov}(X, Y)$  steht

$$E[(X_j - E(X_j))(Y_k - E(Y_k))] = \text{Cov}(X_j, Y_k)$$

also

$$\text{Cov}(X, Y) = (\text{Cov}(X_j, Y_k))_{j=1, \dots, p, k=1, \dots, q}$$

**Lemma 7** Sei  $X$  ein  $p$ -dimensionaler,  $Y$  ein  $q$ -dimensionaler Zufallsvektor.

1.  $\text{Cov}(X, X) = \text{Var}(X)$
2.  $\text{Cov}(X, Y) = E(XY^T) - E(X)[E(Y)]^T$ ,  $\text{Var}(X) = E(XX^T) - E(X)(E(X))^T$
3.  $\text{Var}(a^T X) = a^T \text{Var}(X) a$  für  $a \in \mathbb{R}^p$
4.  $\text{Var}(AX + b) = A \text{Var}(X) A^T$  für  $a \in \mathbb{R}^{n \times p}$ ,  $b \in \mathbb{R}^n$
5. Sei  $p = q$ . Dann gilt  $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + \text{Cov}(X, Y) + \text{Cov}(Y, X)$ . Falls  $X$  und  $Y$  unabhängig sind, dann  $\text{Cov}(X, Y) = \text{Cov}(Y, X) = 0$  und  $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ .
6.  $\text{Var}(X)$  ist symmetrisch und nicht-negativ definit, d.h.  $a^T \text{Var}(X) a \geq 0$ ,  $\forall a \in \mathbb{R}^p$

**Beweis:** Setze  $\mu = E(X)$ ,  $v = E(Y)$

1.  $\text{Cov}(X, Y) = E[(X - \mu)(X - \mu)^T] = \text{Var}(X)$
2.  $\text{Cov}(X, Y) = E[(X - \mu)(Y - v)^T] = E(XY^T - \mu Y^T - Xv^T + \mu v^T) = E(XY^T) - \mu E(Y^T) - E(X)v^T + \mu v^T = E(XY^T - E(X)(E(Y))^T)$ . Daraus folgt mit (a), dass  $\text{Var}(X) = \text{Cov}(X, X) = E(XX^T) - E(X)(E(X))^T$
3. Spezialfall von (d) mit  $A = a^T$ ,  $b = 0$
4.  $\text{Var}(AX + b) = E[(AX + b - E(AX + b))(AX + b - E(AX + b))^T] = AE[(X - E(X))(X - E(X))^T A^T] = A \text{Var}(X) A^T$
5.  $\text{Var}(X + Y) = E[(X + Y)(X + Y)^T] - (E(X + Y))^T = E(XX^T) + E(XY^T) + E(YX^T) + E(YY^T) - E(X)(E(X))^T - E(X)(E(Y))^T - E(Y)(E(X))^T - E(Y)(E(Y))^T = \text{Var}(X) + \text{Cov}(X, Y) + \text{Cov}(Y, X) + \text{Var}(Y)$ . Sind  $X = (X_1, \dots, X_p)^T$  und  $Y = (Y_1, \dots, Y_p)^T$  unabhängig, dann gilt  $E(X_j, Y_k) = E(X_j)E(Y_k)$  also  $\text{Cov}(X_j, Y_k) = 0$ . Daraus folgt  $\text{Cov}(X, Y) = 0$ ,  $\text{Cov}(Y, X) = 0$ .
6.  $\{\text{Var}(X)\}_{jk} = \text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j) = \{\text{Var}(X)\}_{kj}$  für alle  $j, k = 1, \dots, p$ . D.h.  $\text{Var}(X)$  ist symmetrisch. Für alle Vektoren  $a^T \in \mathbb{R}^p$  gilt  $a^T \text{Var}(X) a = \text{Var}(a^T X) \geq 0$  (wegen c).

**Beispiel 8** Sei  $X = (X_1, X_2)$  wie in Bsp. 5. Berechne (i)  $\text{Var}(X)$ , (ii)  $\text{Var}(X_1 - 3X_2)$ , (iii)  $\text{Var}(X_1 + X_2 + 1, 2X_1 - X_2 - 1)^T$ . (i)  $E(X_1) = E(X_2) = \frac{7}{12}$  nach Bsp. 6.

$$E(X_1^2) = \int x_1^2 f_{X_1}(x_1) dx = \int_0^1 x_1^2 (x_1 + \frac{1}{2}) dx = \frac{x_1^4}{4} \Big|_0^1 + \frac{x_1^3}{6} \Big|_0^1 = \frac{1}{4} + \frac{1}{6} = \frac{5}{12} \implies \text{Var}(X_1) = E(X_1^2) - (E(X_1))^2 = \frac{5}{12} - \left(\frac{7}{12}\right)^2 = \frac{11}{144} \text{ Ebenso } \text{Var} X_2 = \frac{11}{144}.$$

$$E(X_1 X_2) = \iint x_1 x_2 f(x_1, x_2) dx_1 dx_2 = \int_0^1 \int_0^1 x_1 x_2 f(x_1, x_2) dx_1 dx_2 = \int_0^1 x_1^2 dx_1 \int_0^1 x_2 dx_2 + \int_0^1 x_1 dx_1 \int_0^1 x_2^2 dx_2 = \frac{1}{3} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{3}$$

$$\text{Cov}(X_1, X_2) = E(X_1 X_2) - E(X_1)E(X_2) = \frac{1}{3} - \frac{7}{12} \cdot \frac{7}{12} = -\frac{1}{144} \implies \text{Var}(X) =$$

$$\begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) \end{pmatrix} = \begin{pmatrix} \frac{11}{144} & -\frac{1}{144} \\ -\frac{1}{144} & \frac{11}{144} \end{pmatrix}$$

(ii) Mit  $a = (1, -3)^T$  ist  $X_1 - 3X_2 = a^T X \implies \text{Var}(X_1 - 3X_2) = \text{Var}(a^T X) = a^T \text{Var}(X) a$ . Einsetzen liefert  $\frac{29}{36}$ . (iii) Mit  $A = \begin{pmatrix} 1 & 1 \\ 2 & -1 \end{pmatrix}$  und  $b = (1, -1)^T$  ist  $AX + b = \begin{pmatrix} X_1 + X_2 + 1 \\ 2X_1 - X_2 - 1 \end{pmatrix} \implies \text{Var}(AX + b) = A \text{Var}(X) A^T$

## 5 Übungsblatt 1

### Aufgabe 1

a)

$$f_{X_1}(x_1) = \int_0^1 f(x_1, x_2) dx_2 = 4x_1 e^{-x_1^2} \int_0^1 x_2 dx_2 = x_1 e^{-x_1^2}, \quad x_1 \geq 0.$$

$$f_{X_1}(x_1) = 0, \quad x_1 < 0$$

b)

$$f_{X_1}(x_2) = \int_0^\infty f(x_1, x_2) dx_1 = 4x_2 \int_0^\infty x_1 e^{-x_1^2} dx_1 = -\frac{e^{-x_1^2}}{2} \Big|_0^\infty = 2x_2, \quad x_2 \in [0, 1]$$

$$\implies f_{X_1}(x_1 | X_2 = \frac{1}{2}) = \frac{f(x_1, \frac{1}{2})}{f_{X_2}(\frac{1}{2})} = 2x_1 e^{-x_1^2}, \quad x_1 \geq 0, x_1 < 0.$$

c)

$$\begin{aligned}
E(X_1) &= \int_0^{\infty} x_1 f_{X_1}(x_1) dx_1 \underbrace{=}_{a)} 2 \int_0^{\infty} x_1^2 e^{-x_1^2} dx_1 \\
&= \int_{-\infty}^{\infty} x_1^2 e^{-x_1^2} dx_1 \underbrace{=}_{x_1 = \frac{t^2}{2}} \int_{-\infty}^{\infty} \frac{t^2}{2} e^{-\frac{t^2}{2}} \frac{1}{\sqrt{2}} dt = \frac{\sqrt{\pi}}{2} \int_{-\infty}^{\infty} t^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \frac{\sqrt{\pi}}{2}
\end{aligned}$$

$$E(X_2) = \int_0^1 x_2 f_{X_2}(x_2) dx_2 \underbrace{=}_{b)} \int_0^1 2x_2^2 dx_2 = \frac{2}{3} \implies E(X) = \left( \frac{\sqrt{\pi}}{2}, \frac{2}{3} \right)^T$$

d) Nach a), b) gilt

$$f_{X_1} f_{X_2} = f(x_1, x_2) \quad \forall x_1, x_2 \in \mathbb{R} \implies X_1, X_2 \text{ sind unabhängig. } \text{Cov}(X_1, X_2) = 0.$$

e)

$$\begin{aligned}
P(X_1 > X_2) &= \int_0^1 \int_{x_2}^{\infty} f(x_1, x_2) dx_1 dx_2 = \int_0^1 4x_2 \int_{x_2}^{\infty} x_1 e^{-x_1^2} dx_1 dx_2 \\
&= \int_0^1 4x_2 - \frac{e^{-x_1^2}}{2} \Big|_{x_1=x_2}^{\infty} dx_2 = \int_0^1 4x_2 \frac{e^{-x_2^2}}{2} dx_2 = -e^{-x_2^2} \Big|_0^1 = 1 - e^{-1}
\end{aligned}$$

## Aufgabe 2

a)

$$\begin{aligned}
1 &= c \int_{-1}^1 \int_{-1}^1 1^1 x_1^2 x_2^2 dx_1 dx_2 = \int_{-1}^1 1^1 \frac{2}{3} + 2x_2^2 dx_2 \\
&= c \left( \frac{4}{3} + \frac{4}{3} \right) = \frac{8c}{3} \implies c = \frac{3}{8}
\end{aligned}$$

b)

Für  $x_1 \in [-1, 1]$  gilt

$$\begin{aligned}
f_{X_1}(x_1) &= \int_{-1}^1 f(x_1, x_2) dx_2 = c \int_{-1}^1 x_1^2 + x_2^2 dx_2 = c(2x_1^2 + \frac{2}{3}) \\
f_{X_2}(x_2|X_1 = x_1) &= \frac{f(x_1, x_2)}{f_{X_1}(x_1)} = \frac{c(x_1^2 + x_2^2)}{c(2x_1^2 + \frac{2}{3})} = \frac{x_1^2 + x_2^2}{2x_1^2 + \frac{2}{3}} \quad \text{falls } x_2 \in [-1, 1]
\end{aligned}$$

$$f_{X_2}(x_2|X_1 = x_1) = 0 \quad \text{für } x_2 \in \mathbb{R} \setminus [-1, 1]$$

c)

$$E(X_1) = \int_{-1}^1 x_1 f_{X_1}(x_1) dx_1 \underbrace{=}_{b)} = c \int_{-1}^1 2x_1^3 + \frac{2x_1}{3} dx_1 = 0 \quad E(X_2) = 0 \quad \text{analog.}$$

$$\text{Cov}(X_1, X_2) = E(X_1 X_2) = c \int_{-1}^1 \int_{-1}^1 x_1 x_2 (x_1^2 + x_2^2) dx_1 dx_2$$

$$= c \int_{-1}^1 \int_{-1}^1 \underbrace{x_1^3 x_2 + x_1 x_2^3}_{\text{ungerade Funktion von } x_1} dx_1 dx_2 = 0$$

d)  $X_1$  und  $X_2$  sind nicht unabhängig, denn nach b) ist die bedingte Dichte der zweiten Variable  $f_{X_2}(x_2|X_1 = x_1)$  nicht unabhängig von  $x_1$ .

**Aufgabe 3** Für  $j = 1, \dots, p$  und alle  $x_j \in \mathbb{R}$  gilt:

$$f_{X_j}(x_j) = \int \cdots \int f(x_1, \dots, x_p) dx_1 \dots dx_{j-1} dx_{j+1} \dots dx_p = \int \cdots \int h_1(x_1) \cdots h_p(x_p) dx_1 \dots dx_{j-1} dx_{j+1} \dots dx_p$$

$$= h_j(x_j) = \prod_{i \neq j} \int h_i(x_i) dx_i \implies f_{X_j}(x_j) = c_j h_j(x_j) \quad \text{für eine Konstante } c_j$$

Wegen  $1 = \int f_{X_j}(x_j) dx_j = c_j \int h_j(x_j) dx_j$  ist  $c_j = \frac{1}{\int h_j(x_j) dx_j}$ .

Für alle  $x_1, \dots, x_p \in \mathbb{R}$  gilt:

$$\begin{aligned} f_{X_1}(x_1), \dots, f_{X_p}(x_p) &= \frac{h_1(x_1)}{\int h_1(u_1) du_1} \cdots \frac{h_p(x_p)}{\int h_p(u_p) du_p} \\ &= \frac{f(x_1, \dots, x_p)}{\int \cdots \int h_1(u_1) \cdots h_p(u_p) du_1 \dots du_p} = \frac{f(x_1, \dots, x_p)}{\int \cdots \int f(u_1, \dots, u_p) du_1 \dots du_p} = f(x_1, \dots, x_p) \end{aligned}$$

Daher sind  $X_1, \dots, X_p$  unabhängig.

## 6 30.10.13

$\text{Cov}(X, Y)$  ist ein Maß für den linearen Zusammenhang zwischen den beiden Zufallsvariablen  $X$  und  $Y$ . Der Wert ist aber schwer interpretierbar, denn er ist maßstabsabhängig.

$$\text{Cov}(aX, bY) = ab\text{Cov}(X, Y) \quad \forall a, b \in \mathbb{R}$$

Man verwendet daher ein standardisiertes Zusammenhangsmaß, nämlich den Korrelationskoeffizienten. Der *Korrelationskoeffizient* von Zufallsvariablen  $X$  und  $Y$  ist definiert durch  $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$ , sofern  $\text{Var}(X), \text{Var}(Y) > 0$ .

( $\text{Var}(X) = 0 \iff P(X = c) = 1$  für ein  $c \in \mathbb{R}$ ).  $\rho$  ist maßstabsunabhängig:

$$\rho(aX, bY) = \frac{ab\text{Cov}(X, Y)}{\sqrt{a^2\text{Var}(X)b^2\text{Var}(Y)}} = \frac{a}{|a|} \frac{b}{|b|} \rho(X, Y), \quad a, b \neq 0$$

Vorzeichen können sich jedoch ändern.

**Satz 9**  $X$  und  $Y$  seien Zufallsvariablen mit  $\text{Var}(X) > 0$  und  $\text{Var}(Y) > 0 \implies -1 \leq \rho(X, Y) \leq 1$ .

$$\rho(X, Y) = 1 \iff \exists \alpha > 0, \beta \in \mathbb{R} \text{ so dass } P(Y = \alpha X + \beta) = 1$$

$$\rho(X, Y) = -1 \iff \exists \alpha < 0, \beta \in \mathbb{R} \text{ so dass } P(Y = \alpha X + \beta) = 1$$

**Lemma 10** Cauchy-Schwarz Ungleichung.

Für Zufallsvariablen  $X$  und  $Y$  gilt  $(E(XY))^2 \leq E(X^2)E(Y^2)$  und

$$(E(XY))^2 = E(X^2)E(Y^2) \iff \exists a, b \neq 0 \in \mathbb{R} : P(aX = bY) = 1$$

**Beweis** Setze  $\alpha = E(Y^2)\beta = E(XY)$ . Behauptung klar, falls  $\alpha = 0$ , da dann  $P(Y = 0) = 1$  und  $(E(XY))^2 = 0 = E(X^2)E(Y^2)$  und es gilt  $P(aX = bY) = 1$  mit  $a = 0, b = 1$ .

Sei nun  $\alpha$  nicht degeneriert, also  $\alpha \geq 0$ .

$$0 \leq E[(\alpha X - \beta Y)^2] = \alpha^2 E(X^2) - 2\alpha\beta \underbrace{E(XY)}_{=\beta} + \beta^2 \underbrace{E(Y^2)}_{=\alpha} = \alpha^2 E(X^2) - \alpha\beta^2 = \alpha(E(Y^2)E(X^2) - (E(XY))^2)$$

$$\underbrace{\implies}_{\alpha > 0} (E(XY))^2 \leq E(X^2)E(Y^2)$$

Falls  $(E(XY))^2 = E(X^2)E(Y^2)$ , dann

$$E[(\alpha X - \beta Y)^2] = 0 \implies P(\alpha X - \beta Y = 0) = 1 \text{ also } P(aX = bY) = 1 \text{ mit } a = \alpha \neq 0, b = \beta$$

Falls  $P(aX = bY) = 1$  mit z.B.  $a \neq 0$  dann  $P(X = \frac{b}{a}Y) = 1$  und

$$(E(XY))^2 = (E(\frac{b}{a}Y^2))^2 = \frac{b^2}{a^2}E(Y^2)E(Y^2) = E(X^2)E(Y^2)$$

### 04.11.13

#### Satz 9

$$-1 \leq \rho(X, Y) \leq 1$$

Cauchy Schwarz:

$$(E(XY))^2 \leq E(X^2)E(Y^2)$$

#### Lemma 10

$X$  und  $Y$  seien Zufallsvariablen mit  $\text{Var}(X) > 0, \text{Var}(Y) > 0$

$$(\rho(X, Y))^2 = \frac{\text{Cov}(X, Y)^2}{\text{Var}(X)\text{Var}(Y)} = \frac{(E[(X - E(X))(Y - E(Y))])^2}{\text{Var}(X)\text{Var}(Y)}$$

$$\underbrace{\leq}_{\text{Lemma 10}} \frac{E[(X - E(X))^2]E[(Y - E(Y))^2]}{\text{Var}(X)\text{Var}(Y)} = 1$$

$$|\rho(X, Y)| = 1 \underbrace{\implies}_{\text{Lemma 10}} \exists a, b \in \mathbb{R}, \text{ nicht beide } = 0, \text{ mit}$$

$$(*) P(a - (X - E(X)) = b(Y - E(Y))) = 1$$

Hier muss zusätzlich  $a \neq 0$  sein, denn sonst  $P(Y = E(Y)) = 1$  im Widerspruch zu  $\text{Var}(Y) > 0$ . Ebenso muss  $b \neq 0$  sein.

Also kann man  $(*)$  schreiben als

$$P(Y = \underbrace{\frac{a}{b}}_{\alpha} X - \underbrace{\frac{a}{b}E(X) + E(Y)}_{\beta})$$

Damit gezeigt

$$|\rho(X, Y) = 1| \implies \exists \alpha \neq 0, \beta \in \mathbb{R} \text{ mit } P(Y = \alpha X + \beta) = 1$$

Bzgl. Vorzeichen von  $\alpha$ :

Falls  $P(Y = \alpha X + \beta) = 1$  mit  $\alpha \neq 0$ , dann

$$\rho(X, Y) = \rho(X, \alpha X + \beta) = \rho(X, \alpha X) = \frac{\alpha \text{Cov}(X, X)}{|\alpha| \text{Var}(X)} = \begin{cases} 1, & \alpha > 0 \\ -1, & \alpha < 0. \end{cases}$$

**Beispiel 11** Betrachte zweimaligen Wurf einer Münze mit  $P(\text{'Kopf'}) = p \in (0, 1)$ .

Sei  $X$  die Anzahl Würfe, in denen Kopf fällt und  $Y$  der Rest. Berechnen nun  $\rho(X, Y)$ . Betrachte Erwartungswerte:

$$E(X) = 2p, \text{Var}(X) = 2p(1-p), E(Y) = 2(1-p), \text{Var}(Y) = 2p(1-p),$$

$$E(XY) = 1 \cdot P(X=1, Y=1) = 2p(1-p)$$

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 2p(1-p) - 4p(1-p) = -2p(1-p)$$

$$\Rightarrow \rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{-2p(1-p)}{2p(1-p)} = -1$$

Hier ist  $P(X = \alpha X + \beta) = 1$  mit  $\alpha = -1$  und  $\beta = 2$ .

Die *Korrelationsmatrix* eines Zufallsvektors  $X(X_1, \dots, X_p)^T$  ist definiert durch die Matrix der einzelnen Korrelationskoeffizienten

$$P = (\rho_{jk})_{j,k=1,\dots,p}, \rho_{jk} = \rho(X_j, X_k).$$

sofern  $\rho_j = \sqrt{\text{Var}(X_j)} > 0$  für alle  $j = 1, \dots, p$ .

$P$  ist die Kovarianzmatrix des Vektors der standardisierten Zufallsvariablen  $Z_j = \frac{X_j - E(X_j)}{\sigma_j}$ .

Mit  $\Delta = \text{diag}(\sigma_1, \dots, \sigma_p)$  gilt

$$P = \text{Var}((Z_1, \dots, Z_p)^T) = \text{Var}(\Delta^{-1}(X - E(X))) \underbrace{=}_{\text{Lemma 7}} \Delta^{-1} \text{Var}(X) \Delta^{-1}.$$

$X_j$  und  $X_k$  heißen *unkorreliert*, falls  $\rho(X_j, X_k) = 0$ .

**Satz 12** Transformationssatz für Dichten.

Sei  $X$  ein  $p$ -dimensionaler Zufallsvektor mit Dichte  $f_X$  (nicht Randdichte!).

Sei  $T = \{x \in \mathbb{R}^p : f_X(x) > 0\}$  Träger von  $X$  und  $M$  sei eine offene Teilmenge von  $T$  mit  $P(X \in M) = 1$ .

Sei  $h : M \rightarrow h(M) \subset \mathbb{R}^p$  eine bijektive Abbildung, stetig differenzierbar mit  $J(x) = \det Dh(x) = \det \frac{\partial h_i(x)}{\partial x_j} \neq 0 \forall x \in M$ .  $D$  ist Differentialoperator.

Dann hat  $Y = h(X)$  die Dichte

$$f_Y(y) = \begin{cases} f_X(h^{-1}(y)) |\det(Dh^{-1}(y))| = \frac{f_X(h^{-1}(y))}{|J(h^{-1}(y))|}, & y \in h(M) \\ 0 & \text{sonst.} \end{cases}$$

**Beispiel 13** Log-Normalverteilung.

Sei  $X \sim N(\mu, \sigma^2)$ , also  $f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp(-\frac{(x-\mu)^2}{2\sigma^2})$ ,  $x \in \mathbb{R}$ .

Hier ist  $p = 1$ ,  $T = \mathbb{R}$ ,  $M = \mathbb{R}$ ,  $h(x) = e^x$ ,  $h(M) = (0, \infty)$ ,  $h^{-1}(y) = \log y$ , Funktionaldeterminante  $J(x) = h'(x) = e^x \neq 0 \forall x \in M$ .



$\Rightarrow Y = h(X)$  hat die Dichte:

$$f_Y(y) \begin{cases} \frac{f_X(h^{-1}(y))}{|J(h^{-1}(y))|} = \frac{f_X(\log y)}{|J(\log y)|} = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\log y - \mu)^2}{2\sigma^2}\right) \frac{1}{y} \\ 0 \end{cases}$$

**Beispiel 14** Sei  $X = (X_1, X_2)^T$  ein 2-dimensionaler Zufallsvektor mit Dichte  $f_X$  und es sei  $T = \{x \in \mathbb{R}^2 : f_X(x) > 0\}$  offen.

Bestimme Dichte von  $Y = \begin{pmatrix} X_1 + X_2 \\ X_1 - X_2 \end{pmatrix}$ .

Setze  $M = T$  und

$$h(x) = \begin{pmatrix} h_1(x) \\ h_2(x) \end{pmatrix} = \begin{pmatrix} x_1 + x_2 \\ x_1 - x_2 \end{pmatrix} \quad \text{für } x = (x_1, x_2)^T \in M$$

$$J(x) = \det\left(\frac{\partial h_i(x)}{\partial x_j}\right)_{i,j=1,2} = \det \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = 2 \neq 0$$

$$h(x) = (Y_1, Y_2)^T \iff \begin{cases} x_1 + x_2 = y_1 \\ x_1 - x_2 = y_2 \end{cases} \iff x_1 = \frac{y_1 + y_2}{2}, x_2 = \frac{y_1 - y_2}{2}$$

Also

$$h^{-1}(y) = \begin{pmatrix} \frac{y_1 + y_2}{2} \\ \frac{y_1 - y_2}{2} \end{pmatrix}$$

Insbesondere ist  $h : M \rightarrow h(M)$  bijektiv.

$\Rightarrow Y$  hat die Dichte

$$f_Y(y) = \begin{cases} \frac{f_X(h^{-1}(y))}{|J(h^{-1}(y))|} = \frac{1}{2} f_X\left(\frac{y_1 + y_2}{2}, \frac{y_1 - y_2}{2}\right), & y \in h(M) \\ 0 & \text{sonst.} \end{cases}$$

Falls  $y \in \mathbb{R}^2 \setminus h(M)$ , dann  $h^{-1}(y) \in \mathbb{R}^2 \setminus M$ , also  $f_X(h^{-1}(y)) = 0$ .

$$f_Y(y) = \frac{1}{2} f_X\left(\frac{y_1 + y_2}{2}, \frac{y_1 - y_2}{2}\right) \quad \forall y \in \mathbb{R}^2$$

Wichtiger Spezialfall: Sind  $X_1$  und  $X_2$  unabhängig, also

$$f_X(x) = f_{X_1}(x_1) f_{X_2}(x_2) \quad \text{für alle } x \in \mathbb{R}$$

Dann hat  $X_1 + X_2$  die Dichte

$$f_{X_1+X_2}(z) = f_{Y_1}(z) = \int_{-\infty}^{\infty} f_Y(z, y_2) dy_2 = \frac{1}{2} \int_{-\infty}^{\infty} f_X\left(\frac{t + y_2}{2}, \frac{z - y_2}{2}\right) dy_2$$

$$= \frac{1}{2} \int_{-\infty}^{\infty} f_{X_1}\left(\frac{z-y^2}{2}\right) f_{X_2}\left(\frac{z-y^2}{2}\right) dy_2 \underbrace{=}_{t=\frac{z+y_2}{2}} \frac{1}{2} \int_{-\infty}^{\infty} f_{X_1}(t) f_{X_2}\left(\frac{z-(2t-z)}{2}\right) 2 dt$$

$$= \int_{-\infty}^{\infty} f_{X_1}(t) f_{X_2}(z-t) dt$$

Dies nennt man Faltung von  $f_{X_1}$  und  $f_{X_2}$ .